Introduction à la programmation parallèle

Master Informatique — Semestre 2 — UE obligatoire de 3 crédits

Année 2017-2018

Version du 1er janvier 2018

Motivations

Si l'écriture de programmes corrects est un exercice difficile, l'écriture de programmes parallèles corrects l'est encore plus. En effet, par rapport à un programme séquentiel, **beaucoup plus de choses peuvent mal tourner** dans un programme parallèle.

Pourquoi s'intéresser alors au parallélisme ?

① Les threads sont une fonctionnalité incontournable du langage Java et permettent de **simplifier** le développement d'applications en transformant du code compliqué en un code plus court et plus structuré.

② En outre, les threads sont le moyen le plus direct d'**exploiter la puissance** des systèmes multiprocesseurs. À mesure que le nombre de coeurs augmente dans les machines, l'exploitation de la concurrence devient incontournable.

La loi de Moore

L'industrie informatique s'est développée depuis 40 ans en s'appuyant sur la loi de Moore, qui incite à changer d'ordinateur tous les deux ans.

En 2004 la perspective de poursuivre la progression des performances selon le modèle classique du monoprocesseur est abandonnée par Intel.

> ≪ *Intel said on Friday that it was scrapping its development of two microprocessors, a move that is a shift in the company's business strategy...* ≫
>
> SAN FRANCISCO, May 7. 2004, New York Times

Depuis lors, la fréquence d'horloge des microprocesseurs s'est stabilisée et la loi de Moore n'est maintenue que par la multiplication du nombre de coeurs.

Fréquence d'horloge des microprocesseurs

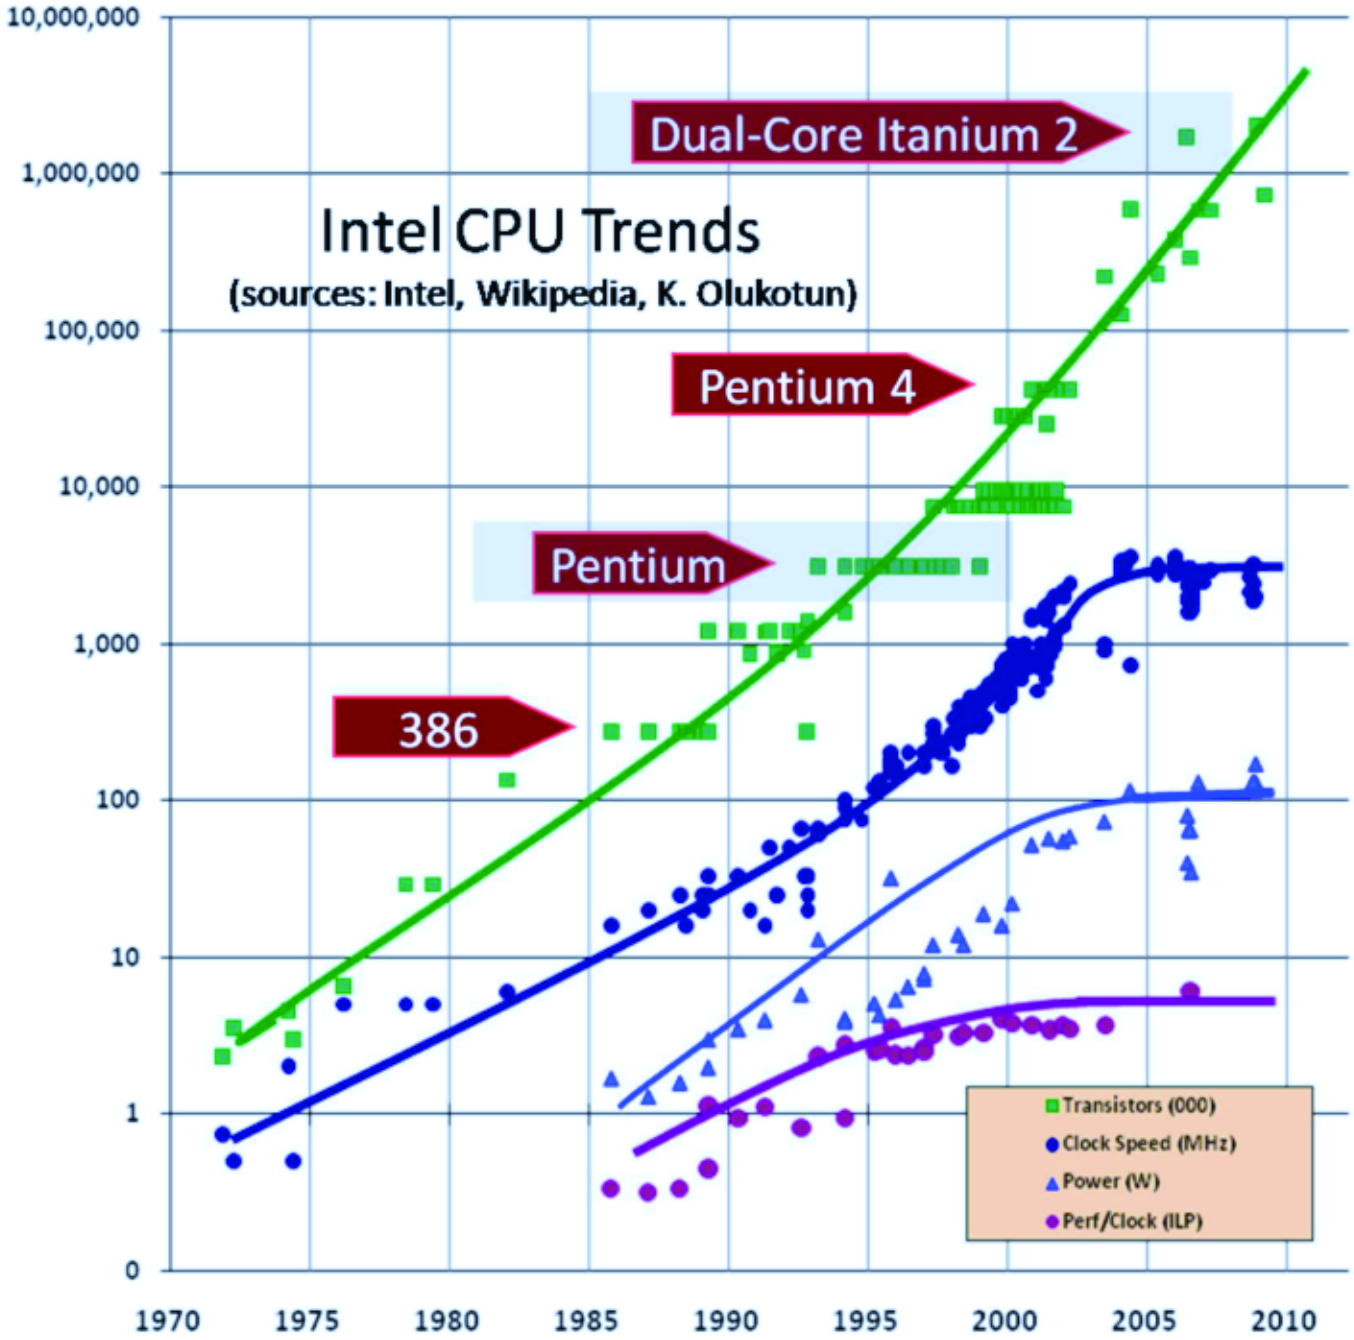

Programmation parallèle : plan du cours

① Threads en Java

⇝ *Les instructions de base*

② Atomicité, verrous, variables de condition et moniteurs

⇝ *Les concepts fondamentaux*

③ Classes ≪ concurrentes ≫ et autres outils en Java

⇝ *Pourquoi réinventer la roue ?*

④ Construction de verrous et programmation sans verrou

⇝ *Question de performance !*

⑤ Le modèle mémoire Java

⇝ *Qu'est-ce qu'un programme ≪ bien synchronisé ? ≫*

Modalités de contrôle des connaissances (alias les MCC)

Il s'agit d'une UE obligatoire de 3 crédits avec 10h. de cours, 10h. de TD et 10h. de TP.

L'examen terminal dure 2h. et se déroule **sans document**.

La note finale $\mathtt{NF}$ se compose de deux notes

- une note d'examen terminal : $\mathtt{ET}$
- une note de projet : $\mathtt{P}$

$$\mathtt{NF} = 0,4 \times \mathtt{P} + 0,6 \times \mathtt{ET}$$

La note de projet $\mathtt{P}$ influe donc sur la note finale ; elle est conservée en seconde session (mais elle peut ne pas être prise en compte).

En seconde session, il y a un nouvel examen terminal $\mathtt{ET'}$.

$$\mathtt{NF} = \max(0,4 \times \mathtt{P} + 0,6 \times \mathtt{ET'}, \mathtt{ET'}).$$

Programmation multithreadée en JAVA

Master Informatique — Semestre 2 — UE obligatoire de 3 crédits

Année 2017-2018

Version du 1er janvier 2018

Thread objet en Java : implémentation

Qu'est-ce qu'un thread ?

C'est un objet qui correspond à un processus indépendant.

Il faut d'abord créer un thread objet puis le lancer pour qu'il s'exécute.

N.B. C'est une différence intéressante avec le **`fork()`** de C, qui crée et lance l'exécution d'un seul coup.

En Java, il y a deux moyens de créer des classes dont les objets correspondent à des threads.

(1) En créant une classe qui **hérite** de la classe **`Thread`**.

Cette classe doit alors implémenter une méthode **`run()`** qui permet de lancer l'objet.

Cette méthode est appelée de manière un peu particulière car il faut faire un appel à **`start()`** pour la lancer !

```
public class Exemple {
  public static void main(String[] args) {
    Thread t = new monThread();
    t.start();
  }
}

public class monThread extends Thread {
  public void run() {
    for (int i = 1;i<=1000;i++)
      System.out.println(i);
  }
}
```

(2) En créant une classe qui **implémente** l'interface **`Runnable`**.

L'héritage multiple étant interdit en Java, cela permet à une classe de threads d'hériter d'une autre classe que la classe Thread.

```
public class Exemple {
  public static void main(String[] args) {
    Thread t = new Thread( new monRunnable() );
    t.start();
  }
}
public class monRunnable implements Runnable {
  public void run() {
    for (int i = 1;i<=1000;i++)
      System.out.println(i);
  }
}
```

Tout en un

```
public class monThread extends Thread {
  public static void main(String[] args) {
    new monThread().start();
    new monThread().start();
  }
  public void run() {
    for (int i = 1;i<=1000;i++) System.out.println(i);
  }
}
```

- Une classe de threads peut contenir le **`main()`** du programme.
- Il est possible de lancer un thread en le créant.
- Il est possible de lancer plusieurs threads qui fonctionnent « en même temps ».

Nous verrons aujourd'hui qu'il est possible aussi de lancer un thread sans utiliser une classe dédiée, mais le code est alors assez peu lisible...

getName() et setName()

Par défaut, le nom d'un thread est « **Thread-** » suivi d'un numéro.

Le nom d'un thread peut être obtenu par la méthode **getName()**.

Le nom d'un thread peut être modifié par la méthode **setName(String)**.

```
public class monThread extends Thread {
  public static void main(String[] args) {
    new monThread().start();
    new monThread().start();
  }
  public void run(){
    for (int i = 1;i<=1000;i++)
      System.out.println(i + "␣" + getName());
  }
}
```

Que voit-on en sortie ?

Gestion des priorités

La priorité d'un thread est un entier compris entre **MAX_PRIORITY** et **MIN_PRIORITY** et vaut **NORM_PRIORITY** par défaut.

Les méthodes **getPriority()** et **setPriority(int)** permettent d'y accéder.

```
public class monThreadBis extends Thread {
  public static void main(String[] args) {
    monThreadBis p1 = new monThreadBis();
    monThreadBis p2 = new monThreadBis();
    p1.setPriority(MAX_PRIORITY);
    p2.setPriority(MIN_PRIORITY);
    p1.start(); p2.start();
  }
  public void run() {
    for (int i = 1;i<=1000;i++)
      System.out.println(i + "␣" + getName());
  }
}
```

- ✔ *Construction d'un thread*
- ✔ *Propriétés d'un thread*
- ☛ *État d'un thread Java*

Pour attendre un temps déterminé, c'est-à-dire *faire une pause* : `sleep()`

`sleep(long millis)` interrompt le déroulement du thread pendant une durée spécifiée en milisecondes.

```
public class monThreadTer extends Thread {
  public static void main(String[] args) {
    monThreadTer p1 = new monThreadTer();
    monThreadTer p2 = new monThreadTer();
    p1.start();  p2.start();
  }
  public void run() {
    for (int i = 1;i<=10;i++){
      System.out.println(i + "␣" + getName());
      sleep(100);
    }
  }
}
```

Ordonnancement des threads

`join()` attend la fin de l'exécution du thread sur lequel elle s'applique. De plus, les variantes

- **`join(long millis)`** et
- **`join(long millis, long nanos)`**

limitent l'attente de la terminaison du thread à une durée spécifiée.

> La variante **`sleep(long millis, long nanos)`** permet aussi de spécifier une durée à une nanoseconde près.

`yield()` interrompt éventuellement le déroulement du thread afin de laisser du temps pour l'exécution des autres threads.

Je déconseille pour commencer d'utiliser yield() !

> La Javadoc dit : « **`static void yield()`** : A hint to the scheduler that the current thread is willing to yield its current use of a processor. »

L'accès d'un thread au(x) processeur(s)

Différents états possibles d'un thread

① exécute son code cible (il a accès à l'un des processeurs pour cela)

② attend l'accès à un processeur (mais pourrait s'exécuter)

③ attend un événement particulier (pour être autorisé à commencer, ou poursuivre, son exécution)

Un thread peut libérer le processeur qu'il occupe

1. s'il exécute une instruction **`yield()`** ;
2. si la tranche de temps allouée est terminée ;
3. s'il exécute une méthode bloquante (**`sleep()`**, **`join()`**, **`read()`**, **`wait()`** ...)

mais ce n'est pas obligatoire...

En fait, c'est l'ordonnanceur de la JVM et le système d'exploitation qui répartissent l'accès et le retrait des threads aux processeurs, en respectant éventuellement les priorités spécifiées et les instructions **`yield()`**.

Différents états d'un thread

Depuis Java 1.5 (Java 5), il est possible de connaître l'*état d'un thread* via la méthode **`getState()`** ; cet état est un élement du type énuméré **`Thread.State`** qui comporte :

NEW : le thread n'a pas encore démarré ;

RUNNABLE : il exécute la méthode **`run()`** de son code ou il attend une *ressource système*, par exemple l'accès à un processeur ;

BLOCKED : il est bloqué en attente d'un *privilège logique*, par exemple de l'acquisition d'un *verrou* ;

WAITING : il est en attente (d'une durée indéfinie) d'un évènement provoqué par un autre thread ;

TIMED_WAITING : il attend qu'une durée s'écoule ou, éventuellement, qu'un évènement soit provoqué par un autre thread ;

TERMINATED : il a fini d'exécuter son code.

Les six états d'un thread

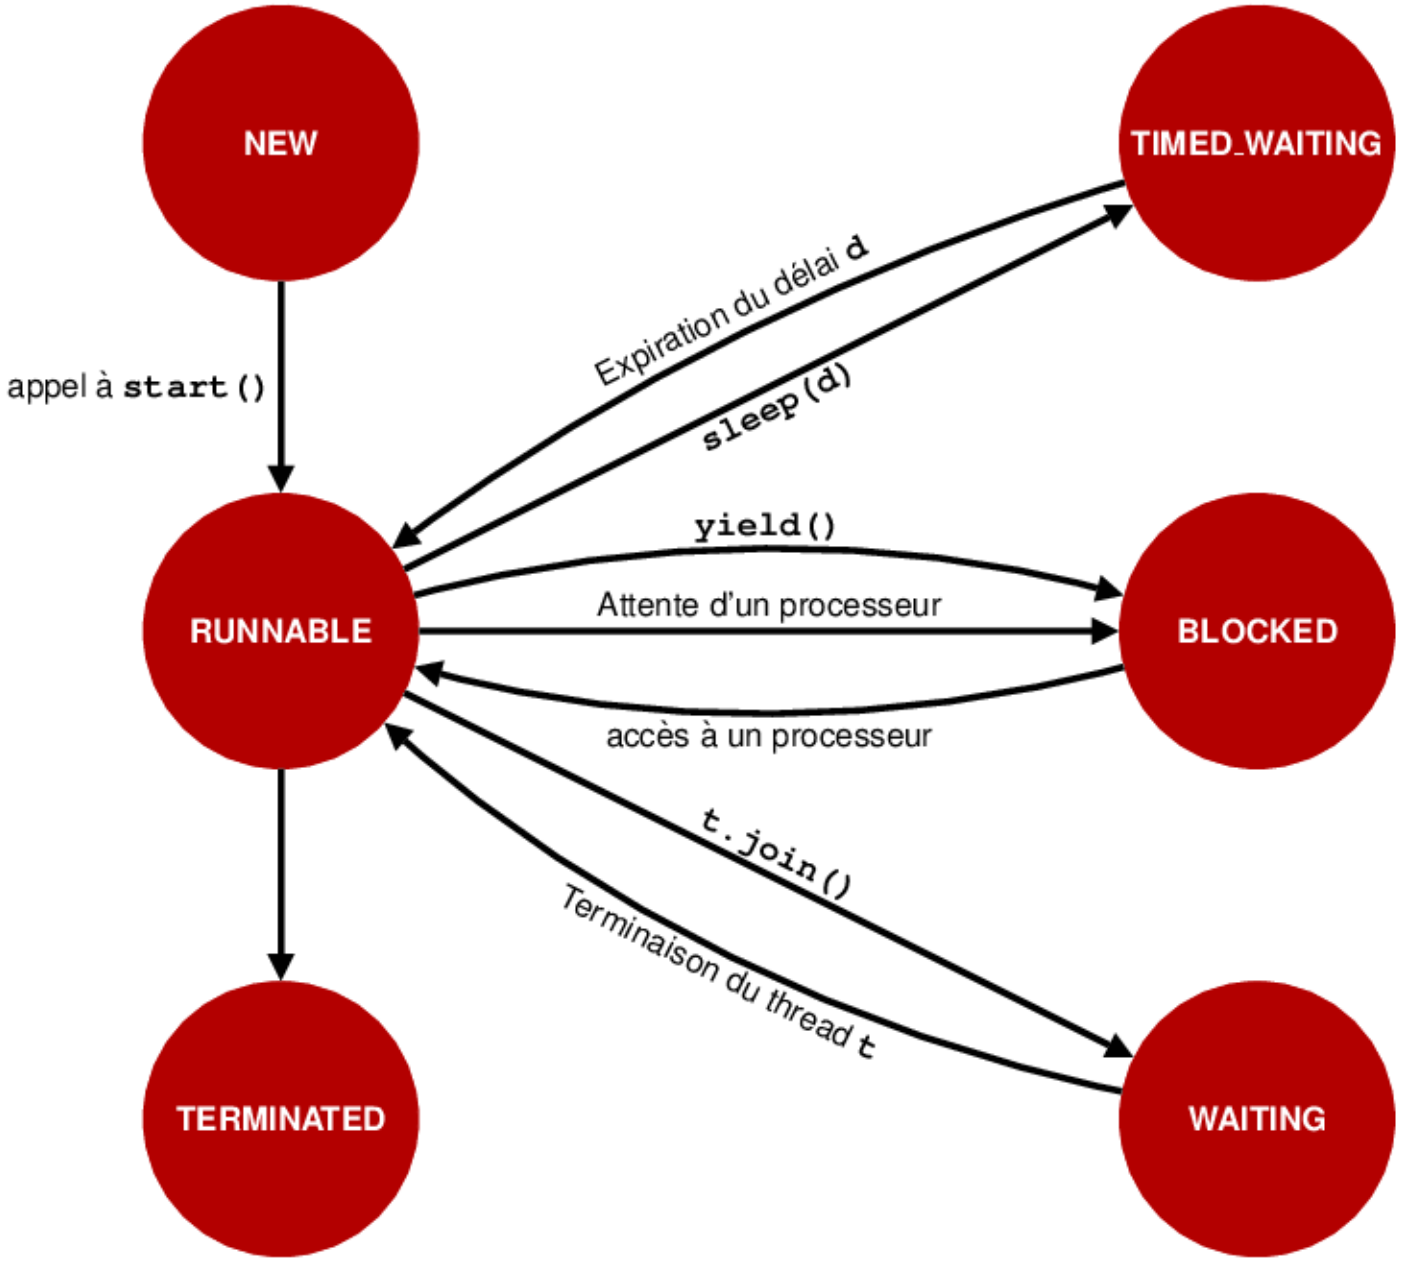

- ✔ *Construction d'un thread*
- ✔ *Propriétés d'un thread*
- ✔ *État d'un thread Java*
- ☛ *Synchronisation et verrous*

Vingt milliers d'incrémentations anarchiques par deux threads

```
public class Compteur extends Thread {
  static volatile int valeur = 0;
  public static void main(String[] args) {
    Compteur Premier = new Compteur();
    Compteur Second = new Compteur();
    Premier.start();
    Second.start();
    Premier.join();
    Second.join();
    System.out.println("La valeur finale est " + valeur);
  }
  public void run(){
    for (int i = 1 ; i<=10000 ; i++)
      valeur++;
  }
}
```

Premier problème de synchronisation

Lorsque deux threads peuvent accéder en même temps à un même objet (ou une variable partagée), il est *très souvent nécessaire* qu'ils ne le fassent qu'*un seul à la fois*. Les accès à l'objet (ou à la variable partagée) doivent alors être *totalement ordonnés*.

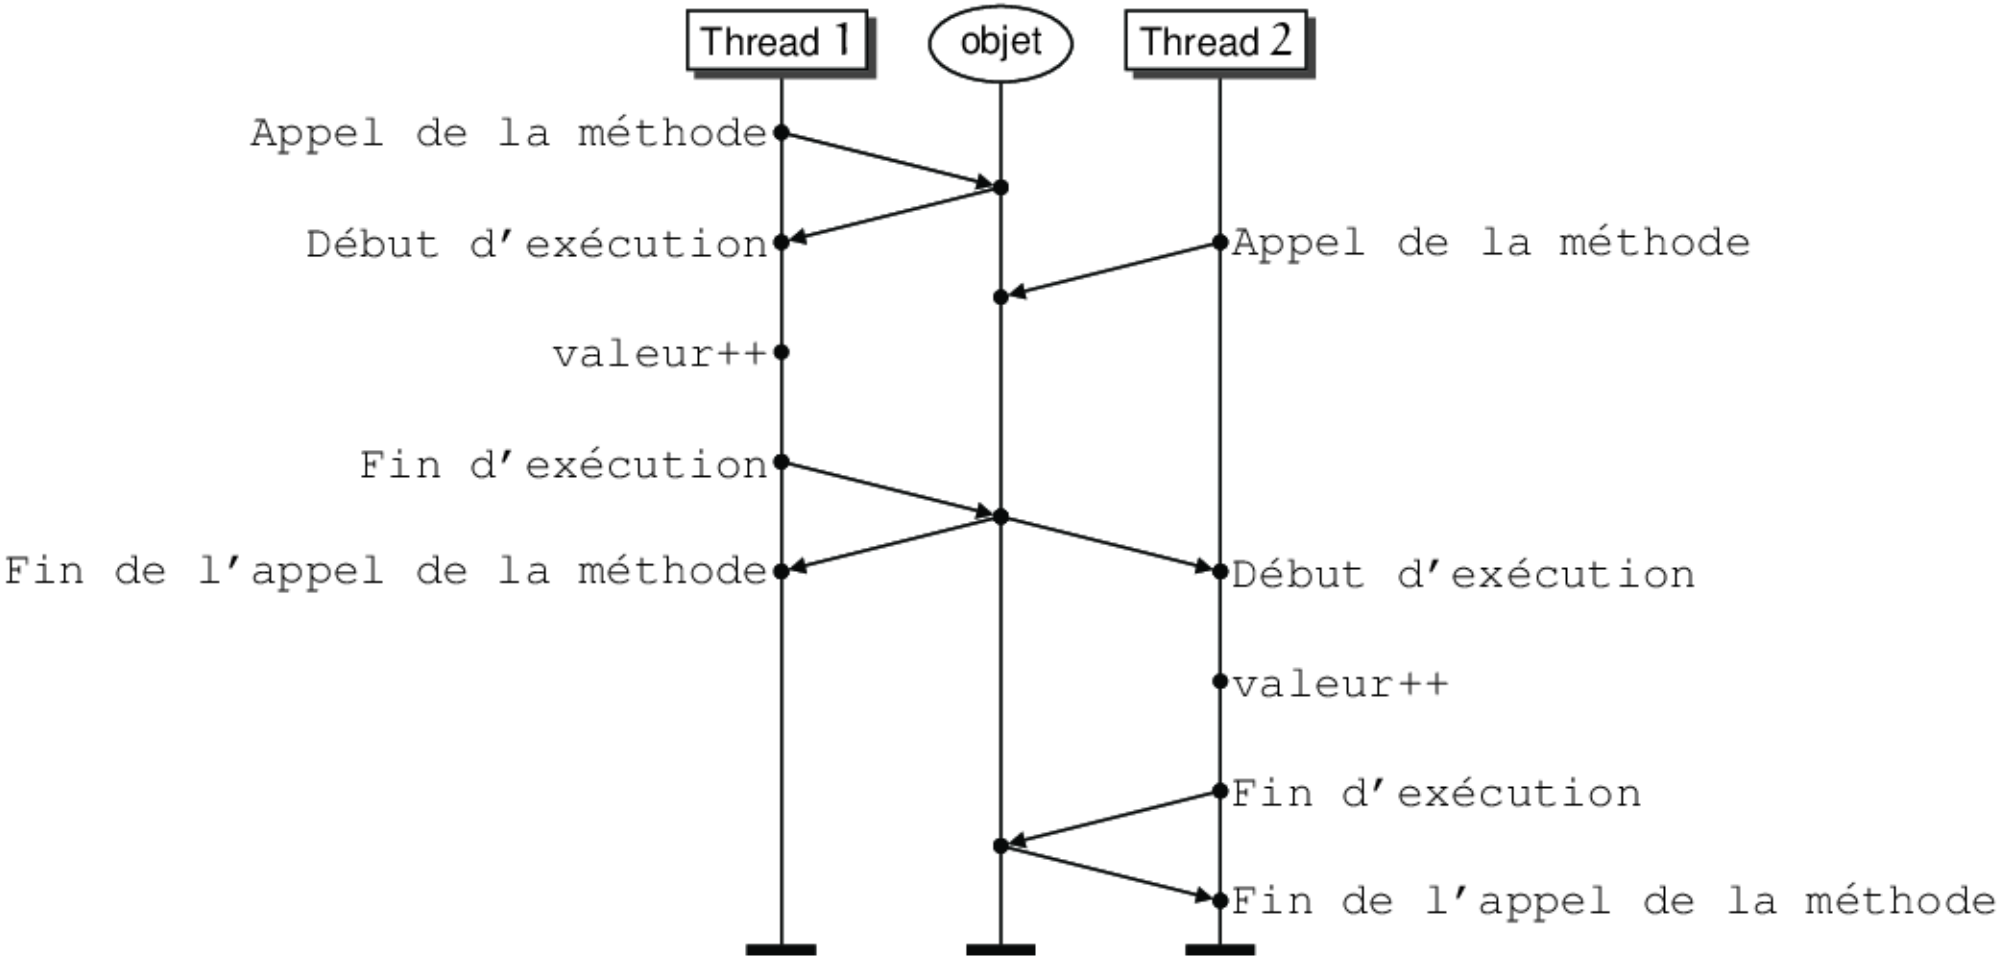

Correction du programme Compteur.java

```
    public void run(){
        for (int i = 1; i <= 10000; i++)
            synchronized (Compteur.class){ valeur++; }
```

```
$ java Compteur
La valeur finale est 20000
$ java Compteur
La valeur finale est 20000
$ java Compteur
La valeur finale est 20000
$ java Compteur
La valeur finale est 20000
$ java Compteur
La valeur finale est 20000
...
```

Il y a désormais « *exclusion mutuelle* » des accès à la variable **`valeur`** : un seul thread incrémentera cette variable à chaque instant : celui qui possède le **verrou**.

Qu'est-ce qu'un verrou ?

Un **verrou** est une variable booléenne qui possède une **liste d'attente** et qui est manipulée uniquement par deux opérations ≪ atomiques ≫ : **`Verrouiller(v)`** et **`Déverrouiller(v)`**.

```
void Verrouiller(verrou v){ // Acquisition du verrou
                            // En anglais: "acquire" ou "lock"
  if (v)
    v = false ;                  // Le verrou n'est plus libre
  else
    suspendre le processus et
    le placer dans la file d'attente associée à v;
}

void Déverrouiller(verrou v){ // Relâchement du verrou
                              // En anglais: "release" ou "unlock"
  if (la file associée à v != vide)
    débloquer un processus en attente dans la file
  else
    v=true ;                     // Le verrou redevient libre
}
```

Fonctionnement d'un bloc « `synchronized` »

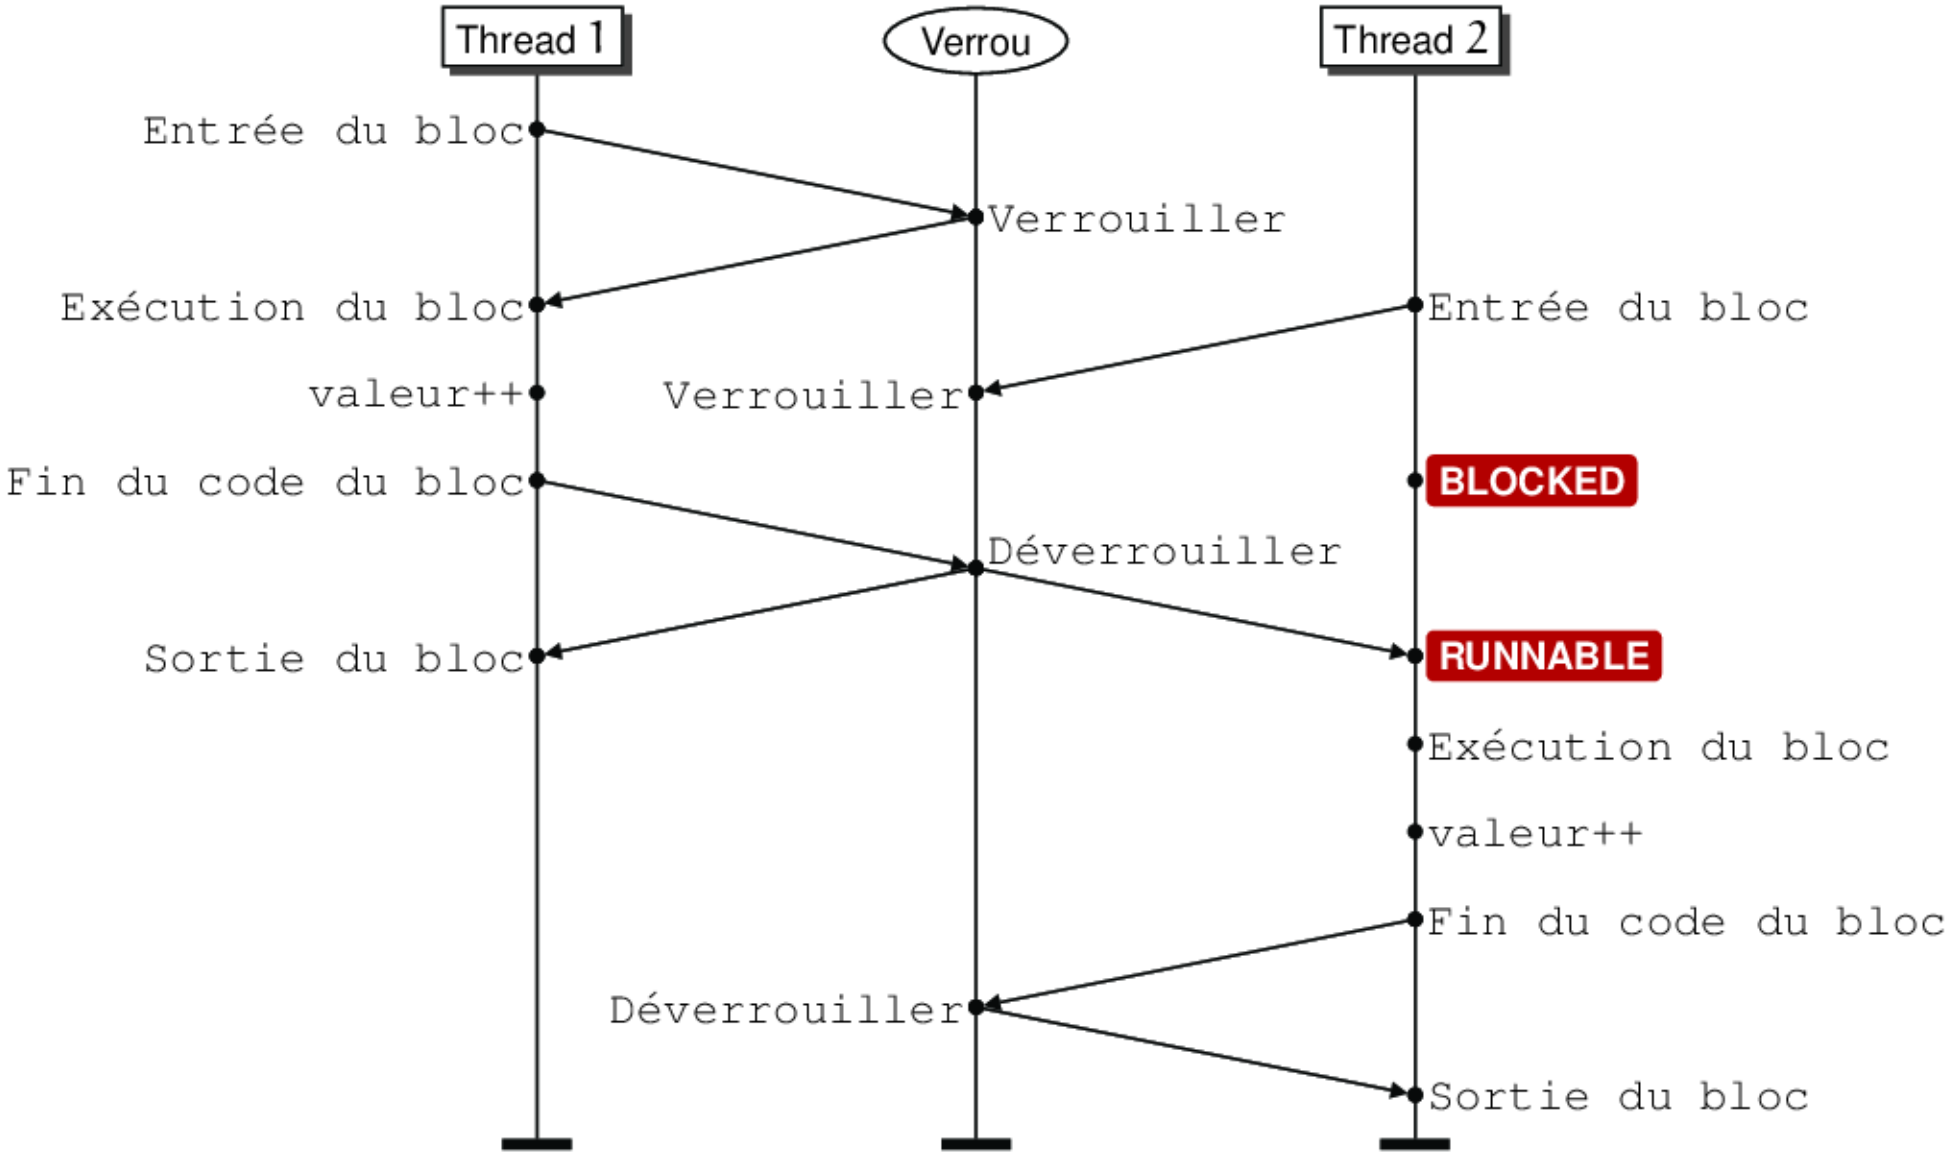

Les verrous intrinsèques et le mot clef « `synchronized` »

En Java, chaque objet comporte en lui-même un verrou, appelé *verrou intrinsèque* (en anglais : « intrinsic lock »).

Il y a des verrous partout !

Un bloc **`synchronized`** requiert avant l'exécution de son code l'acquisition du *verrou intrinsèque* de l'objet indiqué en paramètre. Dans notre exemple, c'est le verrou de la classe **`Compteur.class`**.

Le verrou est relâché lorsque l'exécution du bloc est terminée.

Verrou intrinsèque d'un objet en Java

① Un seul thread peut posséder un verrou donné à un moment donné.

⇝ C'est le principe du verrou !

⇝ Les autres threads qui demandent le même verrou seront placés dans l'état d'attente **BLOCKED**.

② Il est impossible de seulement **tenter** d'acquérir un verrou intrinsèque.

⇝ C'est le principe du verrou : le thread prend le risque d'être bloqué.

③ Si un thread possède le verrou, il peut l'acquérir **à nouveau** !

Il s'agit donc d'un verrou « réentrant ! »

⇝ **Ça évite de se bloquer bêtement soi-même.**

⇝ Alors le verrou sera libéré (ou transmis à un autre thread) lorsqu'il aura été relâché **autant de fois** qu'il a été pris.

Les six états d'un thread (suite)

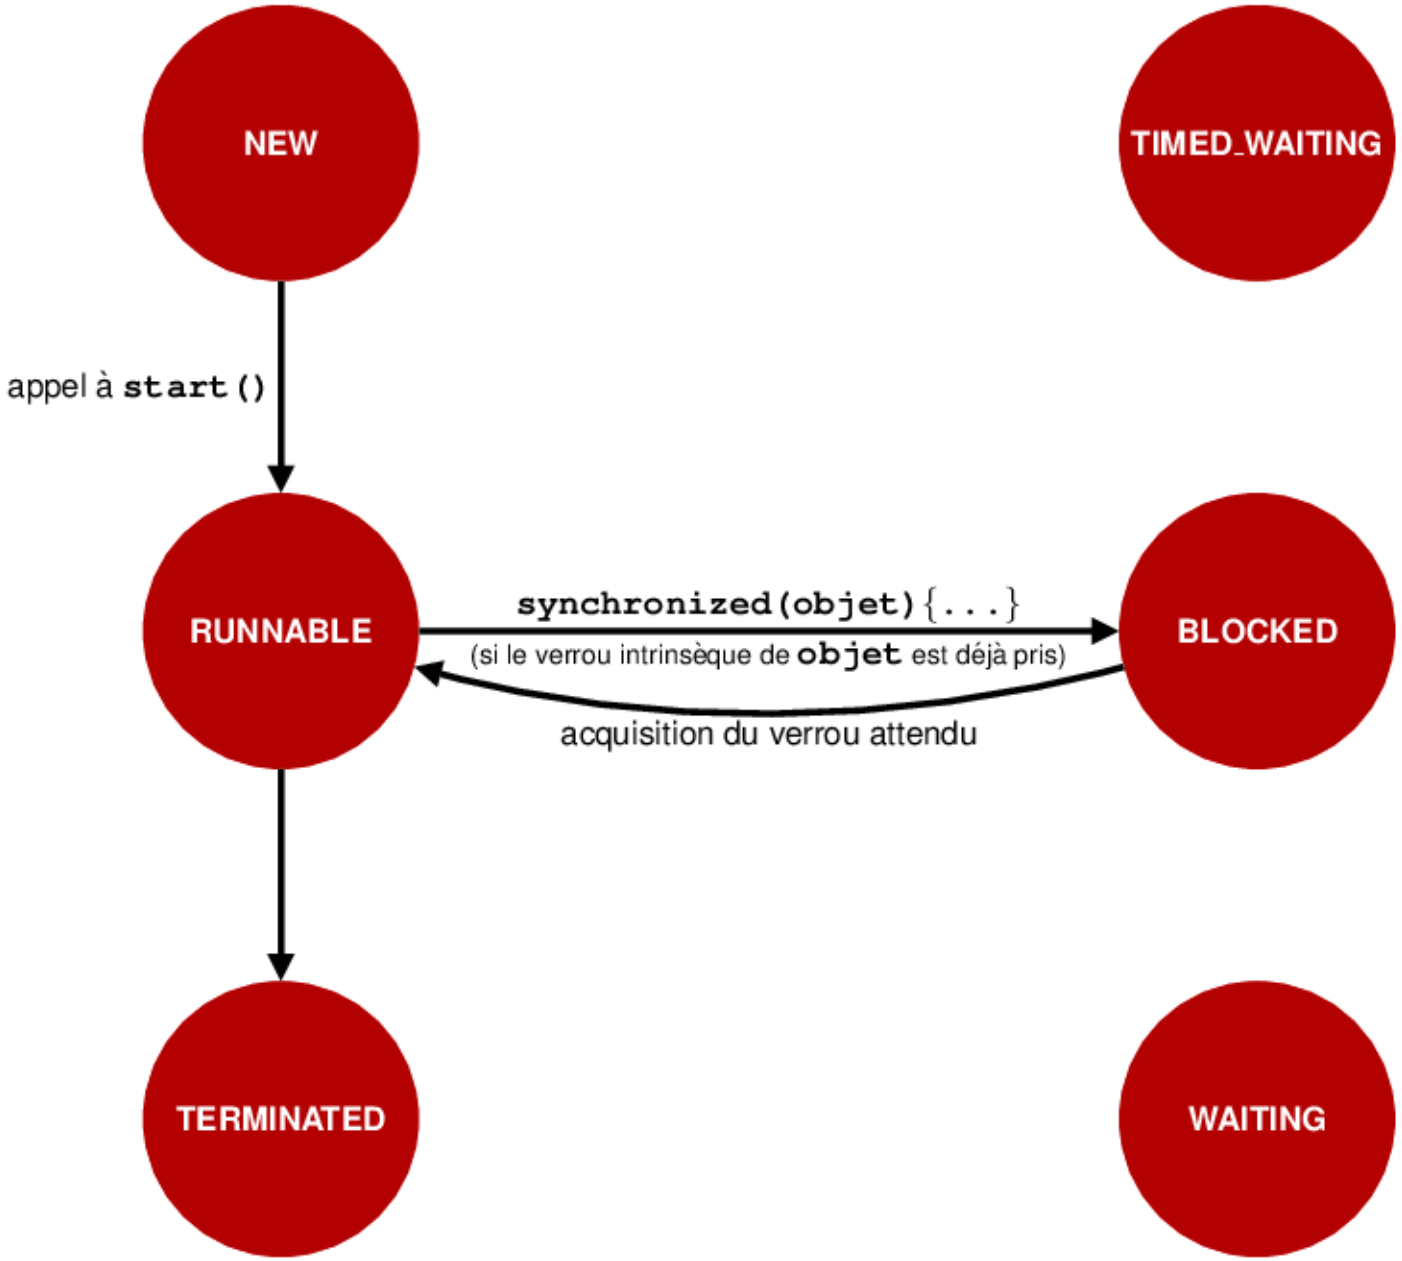

Modificateur `synchronized` d'une méthode

Le modificateur **`synchronized`** d'une méthode revient à exécuter le code de la méthode dans un *bloc* **`synchronized(this)`**`{...}`.

Il y a :
- — acquisition du verrou de **`this`** en entrée de bloc.
- — relâchement du verrou de **`this`** en sortie de bloc.

```
synchronized void inc(){
  compteur++;
}
```

```
void inc(){
  synchronized(this) {
    compteur++;
  }
}
```

Ces deux méthodes sont équivalentes.

Pour être exact, une méthode déclarée **`synchronized`** requiert le verrou de **`this`**, c'est-à-dire de l'objet sur lequel est appliquée la méthode. En revanche une méthode *static* déclarée **`synchronized`** requiert elle le verrou de la classe correspondante (qui est aussi un objet).

Premiers exercices du TD/TP

En guise de premiers exercices, vous écrirez en TD et en TP une version parallèle d'un programme séquentiel, **en vue de l'accélérer**.

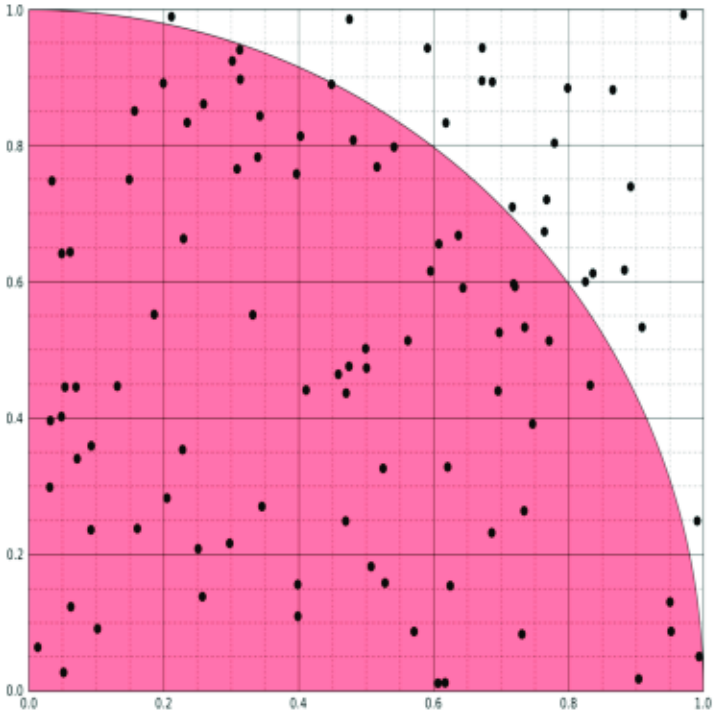

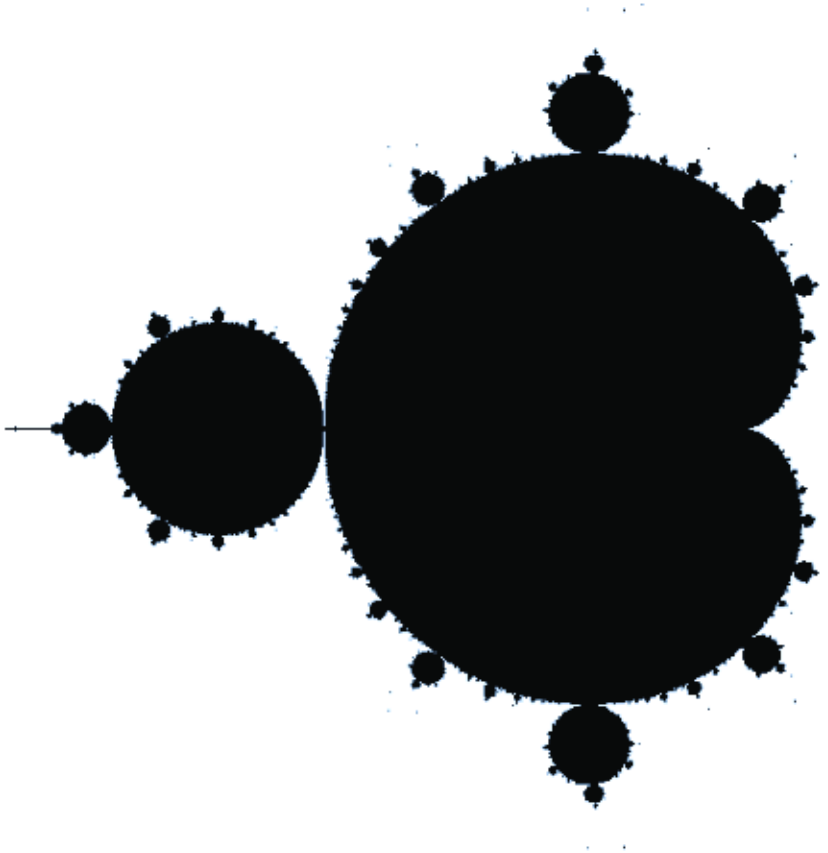

Des exercices plus complexes viendront ensuite...

- ✔ *Construction d'un thread*
- ✔ *Propriétés d'un thread*
- ✔ *État d'un thread Java*
- ✔ *Synchronisation et verrous*
- ☛ *Signaler et attendre en Java*

Second problème de synchronisation

Les threads ont souvent besoin de se coordonner, en particulier quand le résultat de l'un est utilisé par un autre. Ce dernier se place en *attente* de la réception d'un *signal*, à l'aide d'une « variable de condition. »

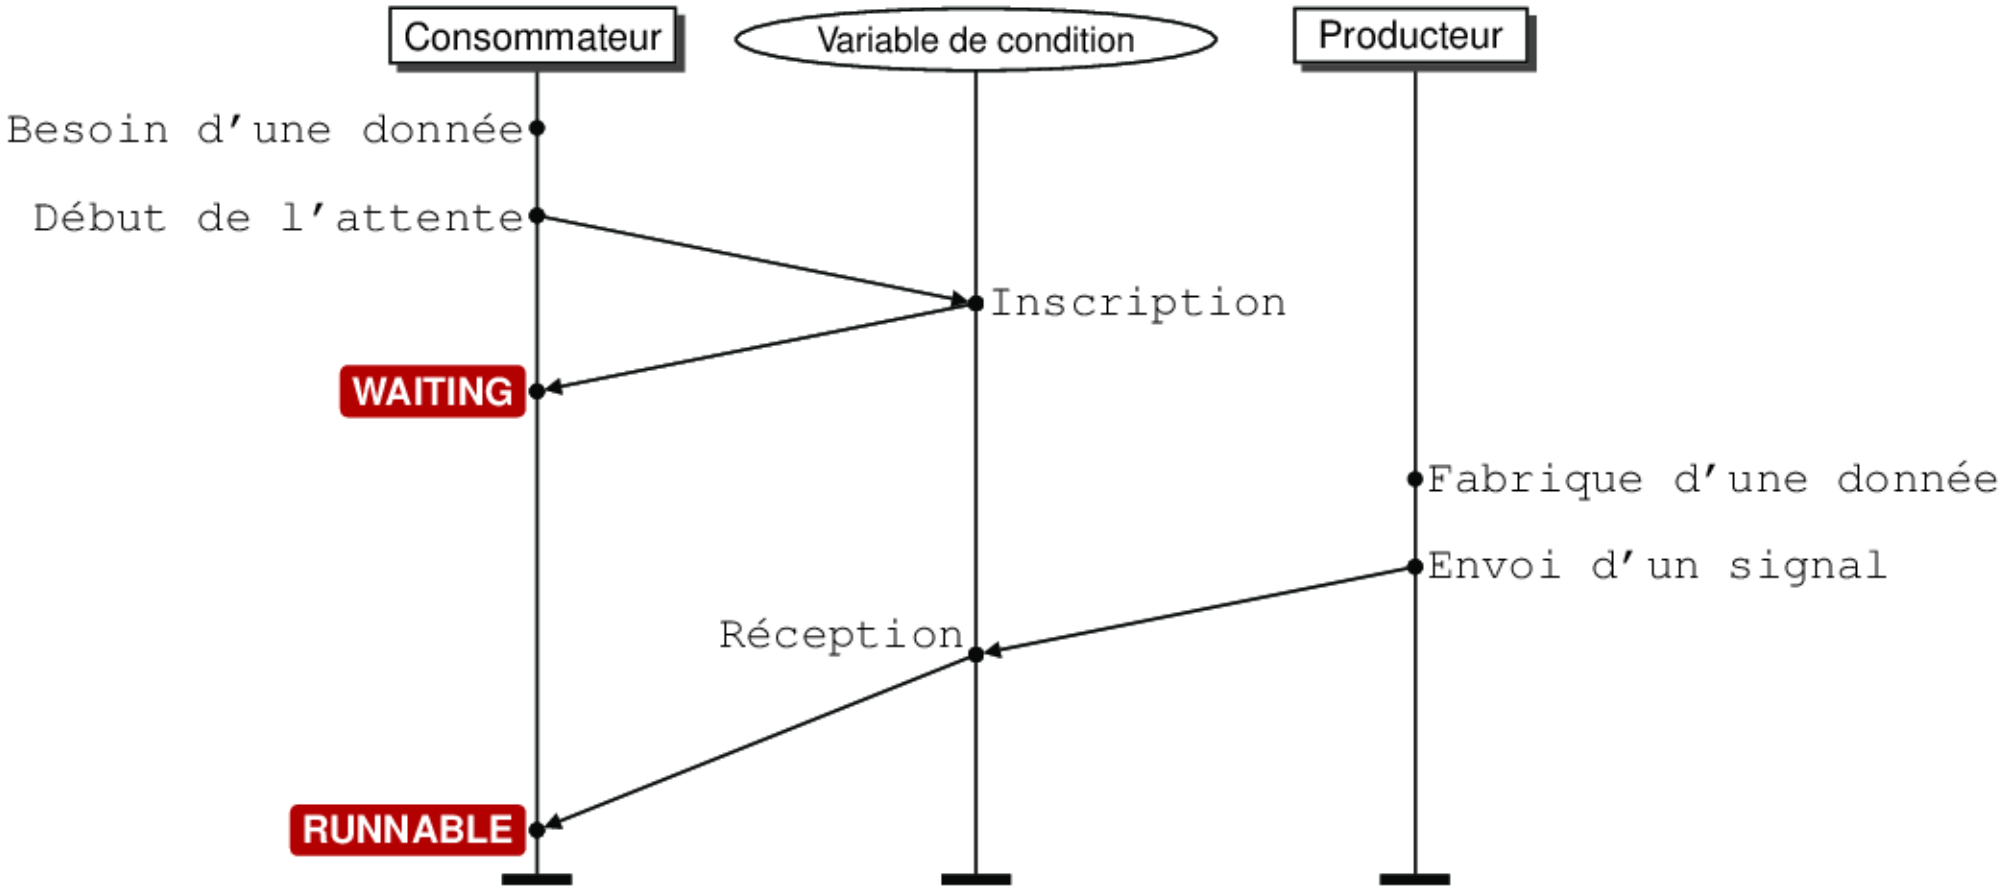

La notion de ≪ variable de condition ≫

Une **variable de condition** est un moyen qui permet de *suspendre* un processus jusqu'à l'arrivée ultérieure d'un ≪ signal. ≫

La valeur d'une variable de condition **`cv`** est constituée par l'ensemble (ou la file) des processus qui *attendent* un signal.

Trois opérations ≪ atomiques ≫ permettent d'accéder à cette valeur.

① La mise en attente d'un processus, c'est-à-dire l'ajout à la fin de la file est obtenue via l'opération **`wait(cv)`**.

② La réactivation d'un processus en attente est effectuée par l'opération **`signal(cv)`**.

Cette opération n'a aucun effet si la file est vide.

③ La fonction **`empty(cv)`** permet de déterminer si la file associée est vide.

Attente et envoi d'un signal en Java

Chaque objet en Java comporte en lui-même une variable de condition. Il est possible d'appliquer les méthodes ci-dessous sur n'importe quel objet !

`wait()` *Suspend* le thread qui appelle cette méthode jusqu'à un appel à **`notify()`** ou **`notifyAll()`** sur le *même* objet par un *autre* thread.

Le thread attend donc sur un objet précis !

`notify()` Redémarre le thread qui a appelé **`wait()`** sur cet objet. S'il y en a plusieurs, ce ne sera pas obligatoirement le premier ! S'il n'y en a aucun, **`notify()`** ne fait rien...

`notifyAll()` Redémarre tous les threads qui ont appelé **`wait()`** sur cet objet.

Un exemple de moniteur qui protège une donnée

```
class Moniteur {
  private int data = 0;

  synchronized int renvoyer(){
    wait();
    return data;
  }

  synchronized void unitialiser(){
    Thread.sleep(1000);
    data = 1;
    notify();
  }
}
```

Principe approximatif de l'exécution

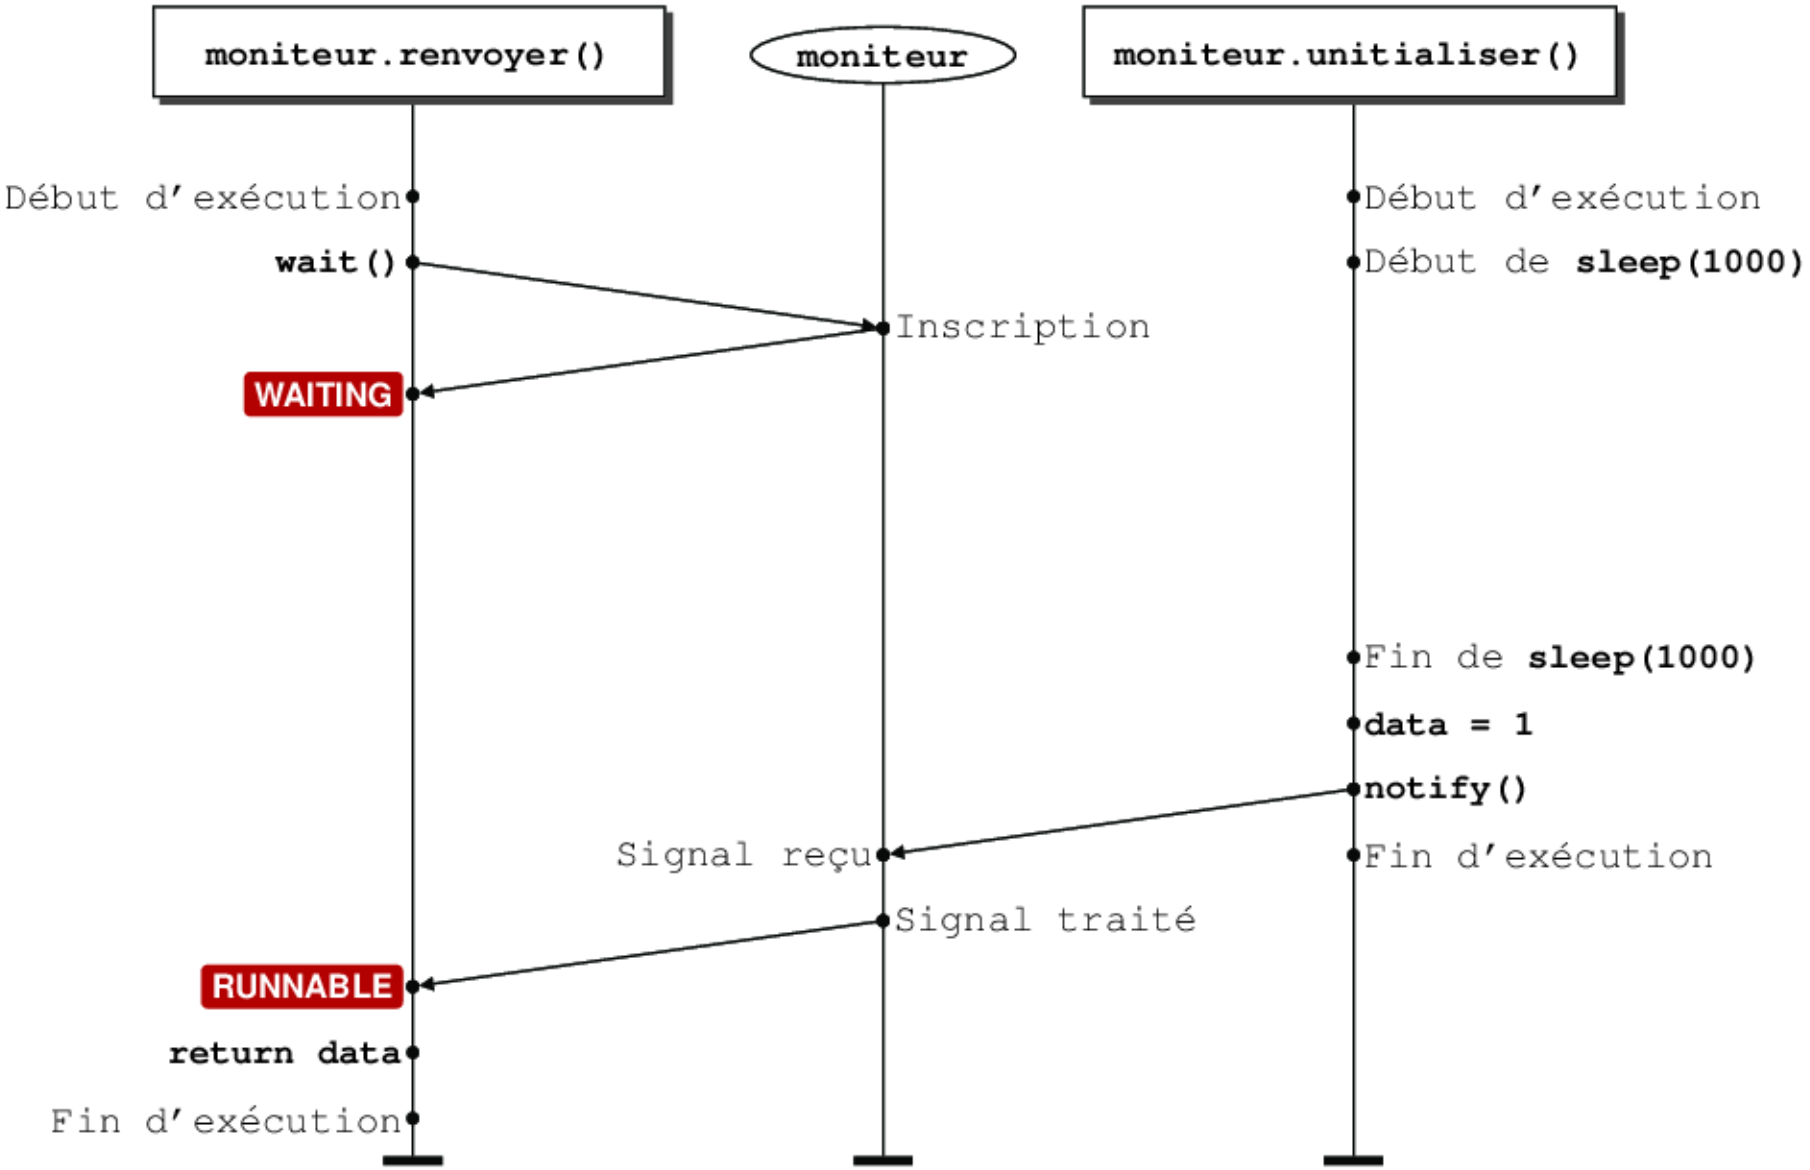

Ce scenario est-il vraiment envisageable ?

Disciplines de signalisation : deux types de variables de condition

Pour diverses raisons, une variable de condition est toujours associée à un *verrou*, *qu'il faut posséder pour pouvoir la manipuler*.

C'est une contrainte adoptée par Java !

Naturellement, le verrou est relâché lorsqu'un thread se place en attente.

Deux approches sont possibles en général pour définir l'effet de **`signal(cv)`**, en tenant compte du fait que *le processus qui exécute cette opération est celui qui possède le verrou.*

① **Signaler et Attendre** : le processus qui signale cède le verrou à celui qui vient d'être activé.

② **Signaler et Continuer** : le processus qui exécute l'instruction **`signal(cv)`** *conserve le verrou* (et poursuit donc son exécution). Le processus qui a reçu le signal sera exécuté plus tard, *lorsqu'il aura obtenu le verrou.*

La seconde discipline est une approche non-préemptive ; elle est plus récente, mais c'est celle la plus couramment utilisée (Unix, Java, Pthreads).

Ce système peut bloquer ! (mais ce n'est pas un interblocage)

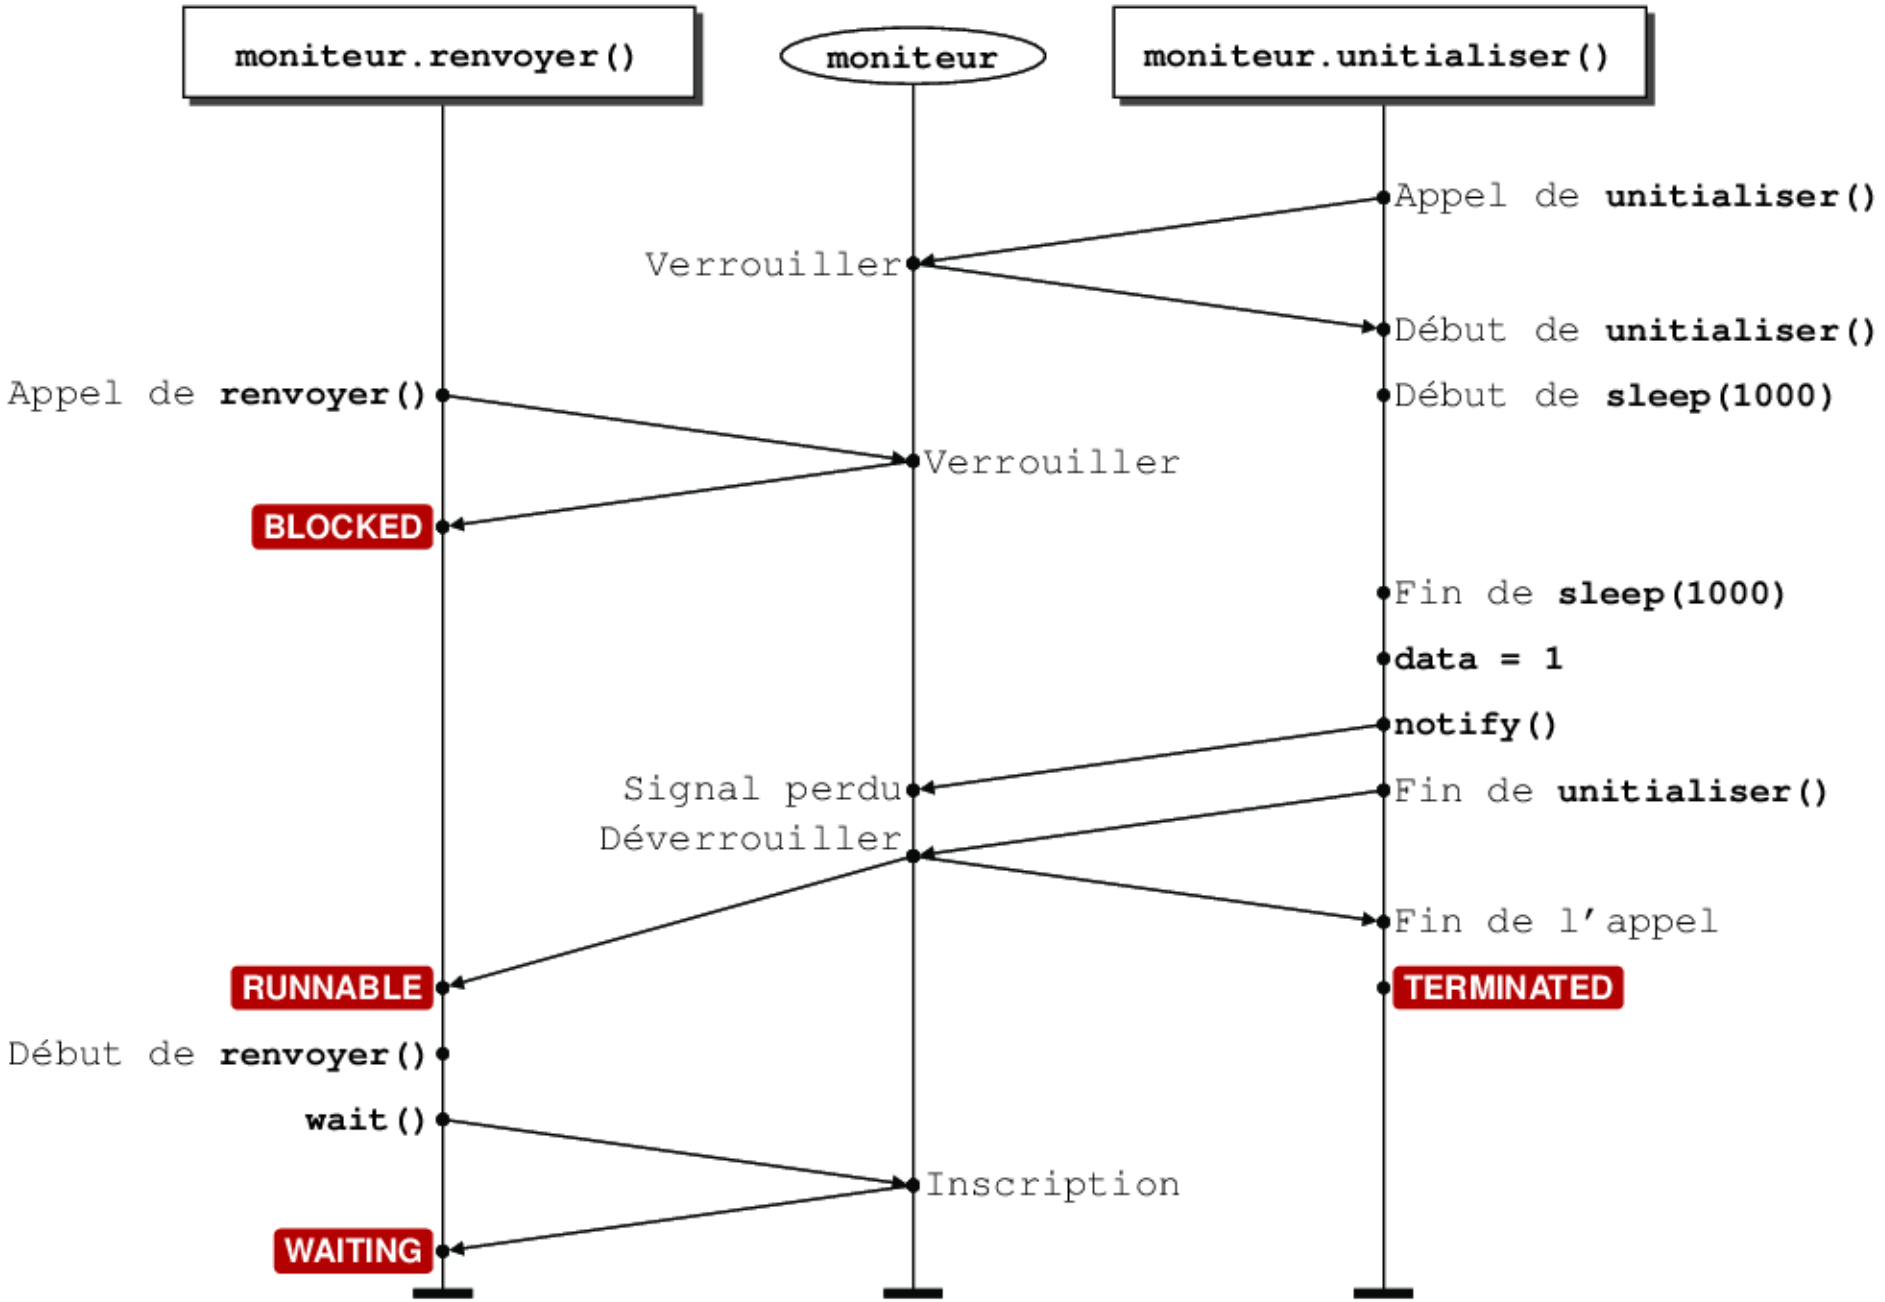

Ce système termine parfois...

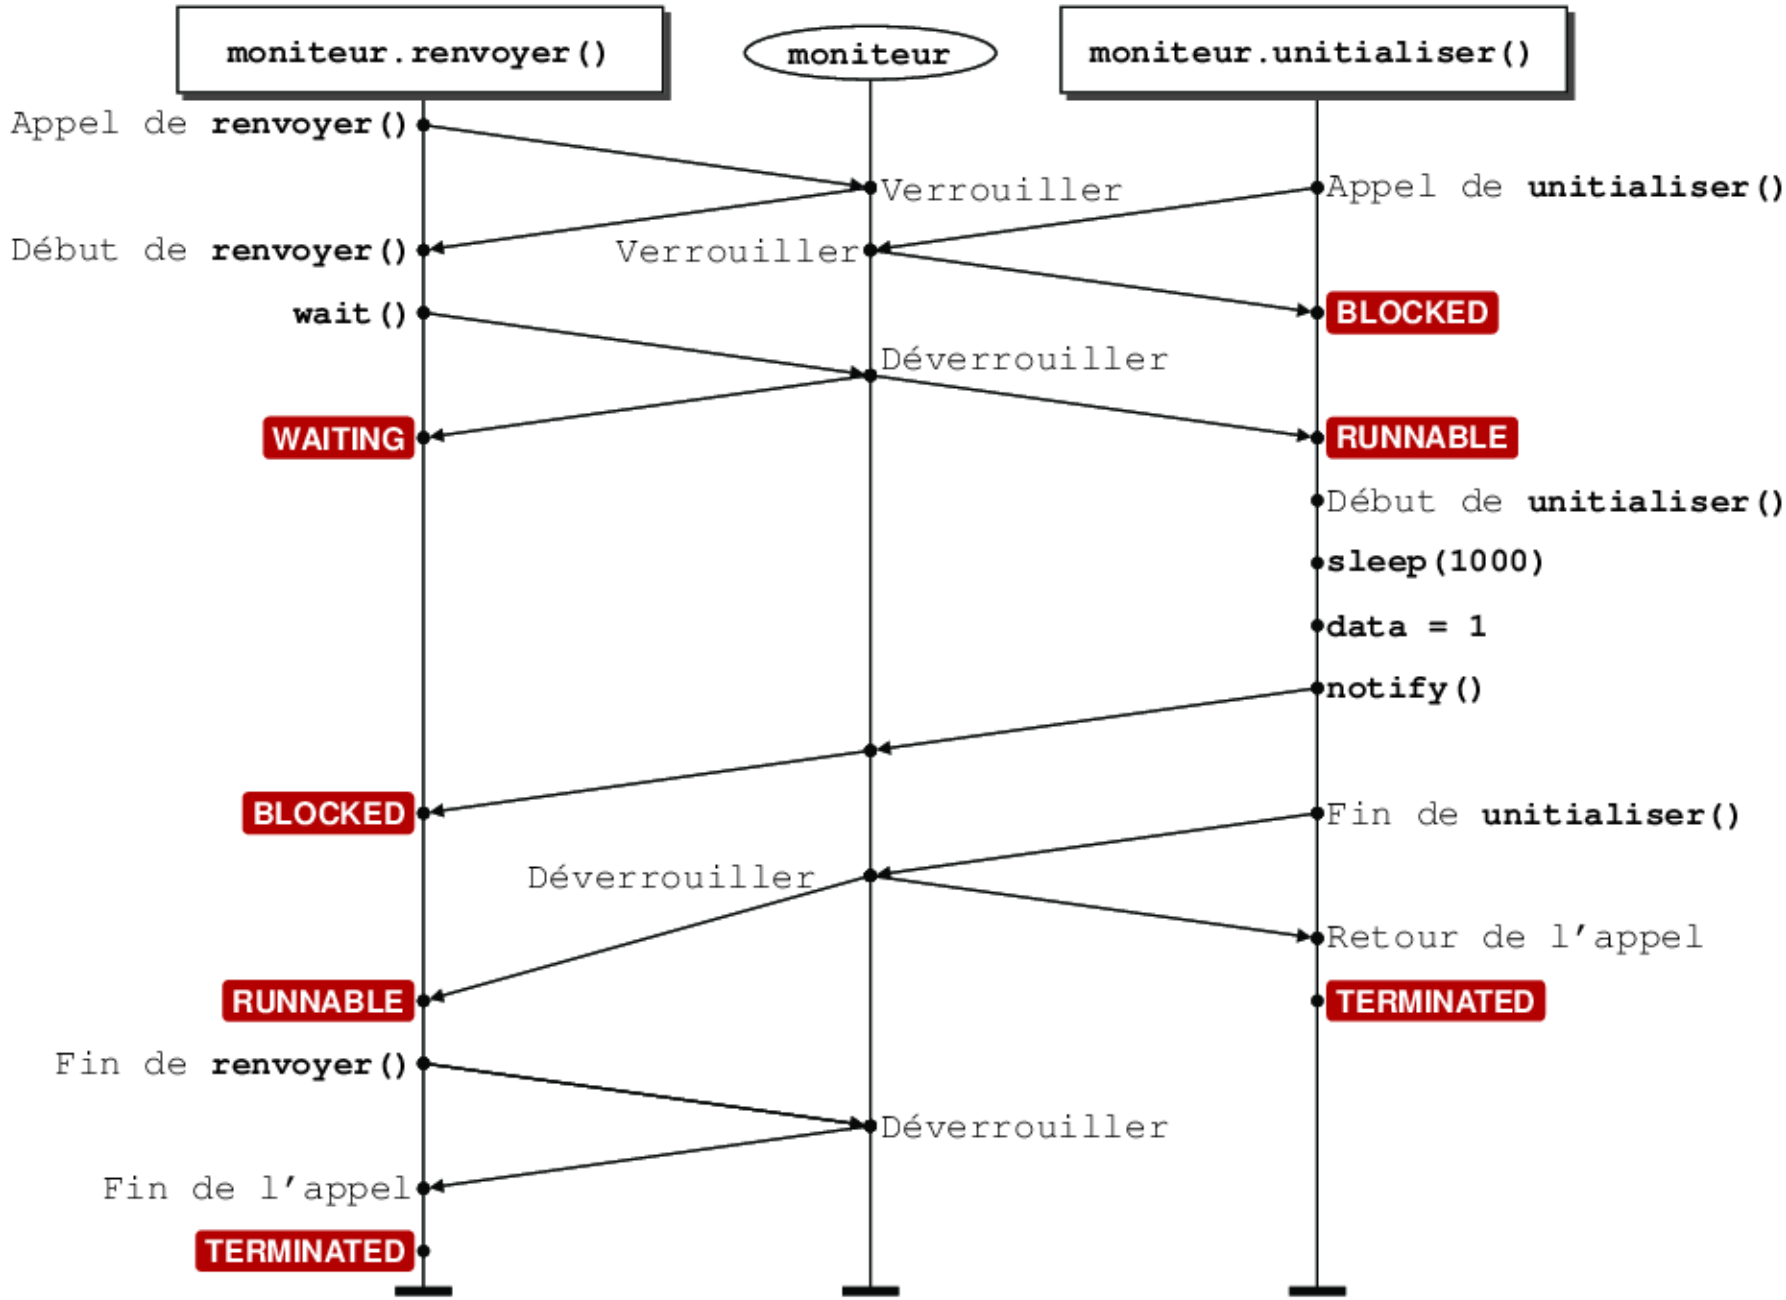

Les méthodes `wait()` et `notify()` avec `synchronized()`

Les méthodes **`wait()`** et **`notify()`** doivent être appelées à l'intérieur d'un bloc (ou d'une méthode) **`synchronized`** appliqué au même objet **`a`**.

`a.wait()`

⇝ inscrit le thread courant sur la liste d'attente de la variable de condition de **`a`** ;

⇝ suspend le thread qui entre alors dans l'état **WAITING** ;

⇝ *relâche le verrou intrinsèque* de **`a`**.

`a.notify()`

⇝ *garde pour lui le verrou intrinsèque* de **`a`** ;

⇝ relance un thread placé sur la liste d'attente de **`a`** s'il y en a un, en le retirant de la liste d'attente. Ce thread passe dans l'état **BLOCKED** et doit récupérer le verrou avant de redémarrer.

Il n'y a aucun contrôle sur le thread choisi !

`a.notifyAll()` relance tous les threads de la liste d'attente.

Les six états d'un thread (fin)

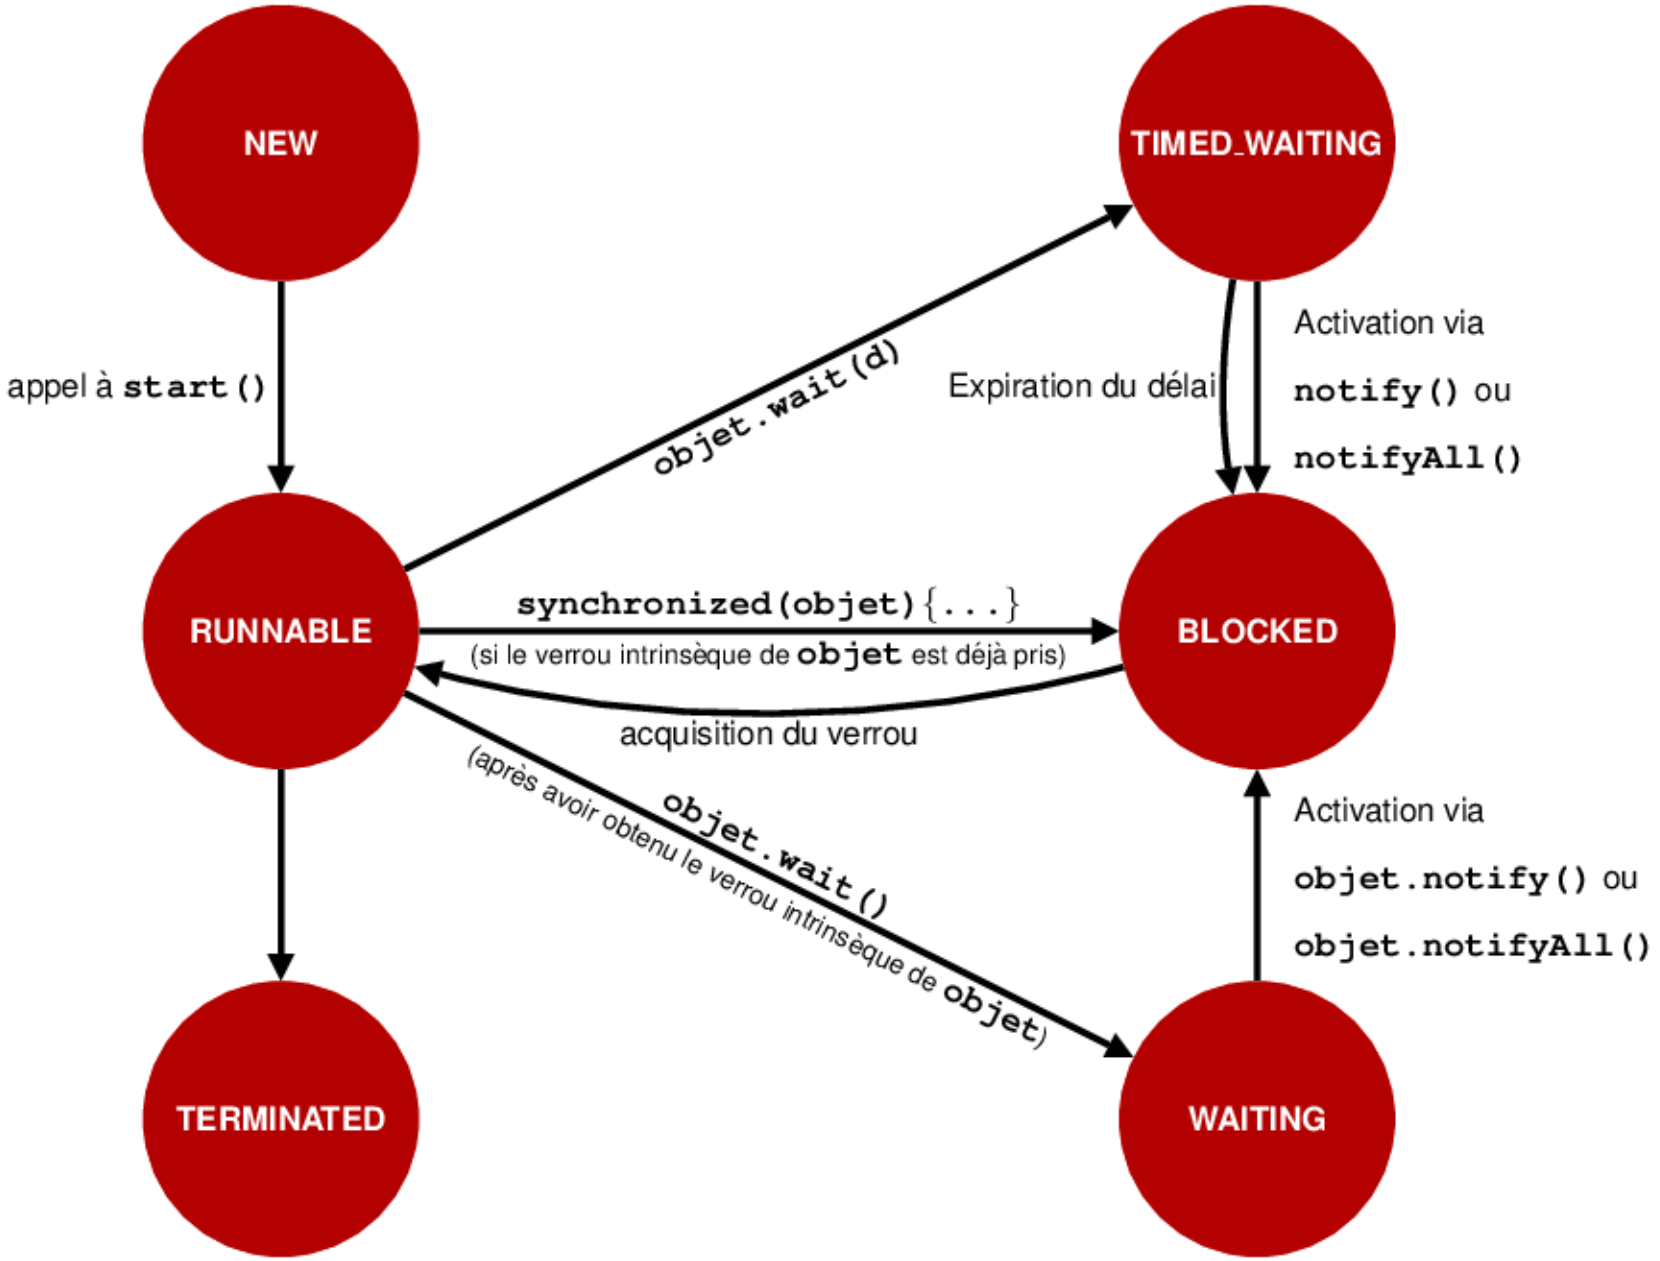

- ✔ *Construction d'un thread*
- ✔ *Propriétés d'un thread*
- ✔ *État d'un thread Java*
- ✔ *Synchronisation et verrous*
- ✔ *Signaler et attendre en Java*
- ☛ *Le mot-clef « volatile »*

Un problème de vue (à tester chez soi)

```
public class Exemple {
  public static void main(String[] args) throws Exception {
    A a = new A();      // Création d'un objet a de la classe A
    a.start();          // Lancement du thread a
    a.fin = true;       // Fin du thread a
  }
  static class A extends Thread {
    public boolean fin = false;
    public void run() {
      while(! fin) ;   // Attente active
    }
  }
}
```

Ce programme termine-t-il ? Pourquoi ?

Solution : le modificateur `volatile`

```
static class A extends Thread {
  public volatile boolean fin = false;
  public void run() {
    while(! fin) ;  // Attente active
  }
}
```

Lorsqu'une variable est utilisée par plusieurs threads, le modificateur **`volatile`** assure que chaque modification de la valeur de la variable est prise en compte par tous les threads.

Plus précisément, le **modèle mémoire Java** (JSR-133) spécifie quelles modifications réalisées par un thread seront « vues » par les autres threads.

Ce qu'il faut retenir

Les priorités des threads et la méthode **`yield()`** ne servent a priori à rien, pour commencer.

Les champs d'un objet susceptibles d'être accédés par plusieurs threads doivent *a priori* être déclarés **`volatile`** par précaution.

Les *verrous* associés aux objets en Java sont un outil fondamental pour écrire un programme correct en Java. La syntaxe de **`synchronized`** assure que chaque verrou pris sera relâché (à la fin du bloc).

`sleep()` permet de faire une pause *un temps déterminé*.

`wait()` permet à un thread *d'attendre sur un objet* jusqu'à ce qu'un autre thread lui lance un *signal*, via un appel **`notify()`** ou **`notifyAll()`** sur cet objet.

La méthode **`wait()`** nécessite d'acquérir au préalable le verrou intrinsèque de l'objet sur lequel elle est appliquée, à l'aide de **`synchronized`**. *Mais ce verrou est alors relâché !*
Les méthodes **`notify()`** et **`notifyAll()`** nécessitent également au préalable **`synchronized`**, mais *ces méthodes ne relâchent pas le verrou !*

Attente active vs attente passive

Master Informatique — Semestre 2 — UE obligatoire de 3 crédits

Année 2017-2018

Version du 1er janvier 2018

Le benchmark adopté : les compteurs en rond

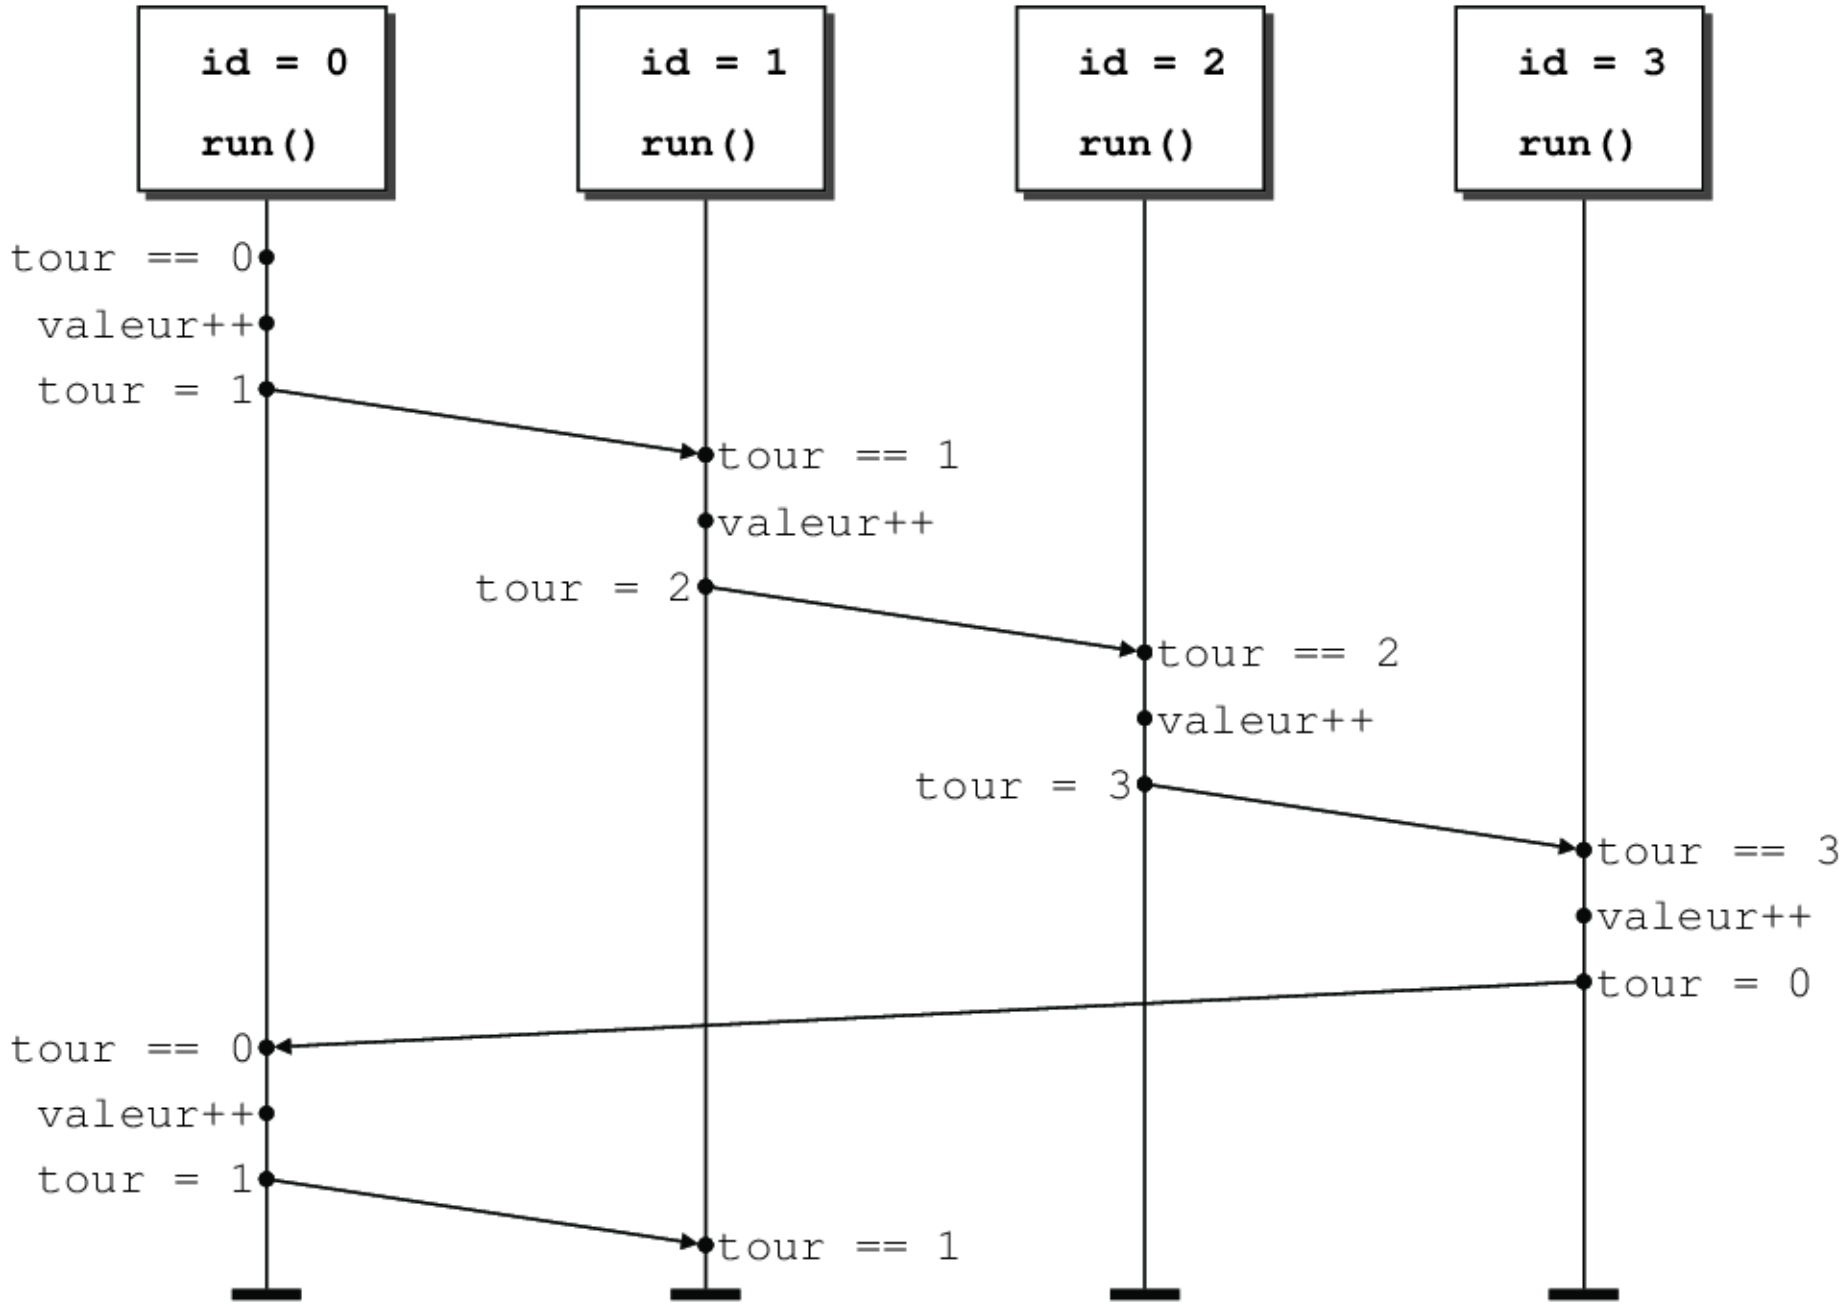

Le benchmark adopté : attente active

```
final int id;                                  // Identité de chaque thread
static volatile int valeur = 0;                // La variable à incrémenter
static volatile int tour = 0;                  // Tour de rôle circulant

static final int valeur_finale = 840;// Nombre d'incrémentations
static int nombre_de_compteurs;                // Nombre de threads utilisés
static final int part = valeur_finale / nombre_de_compteurs ;
...
public void run(){
  for (int i = 1; i <= part; i++){
    while(tour != id);                         // Attente active du tour
    valeur++;
    tour = (tour+1) % nombre_de_compteurs;
  }
}
```

Alternative à l'attente active : l'attente passive

La méthode **`run()`** alternative place les threads en *attente passive (sur une variable de condition)* via un appel à **`wait()`** sur un objet **`rendezvous`** partagé.

```
static private Object rendezvous = new Object();
...
public void run(){
  for (int i = 1; i <= part; i++){
    synchronized(rendezvous){
      while(tour!=id) rendezvous.wait();     // Attente passive
      valeur++;
      tour = (tour+1) % nombre_de_compteurs;
      rendezvous.notifyAll();
    }
  }
}
```

Pourquoi faut-il réveiller tout le monde ?

Premiers résultats, sur une machine monoprocesseur

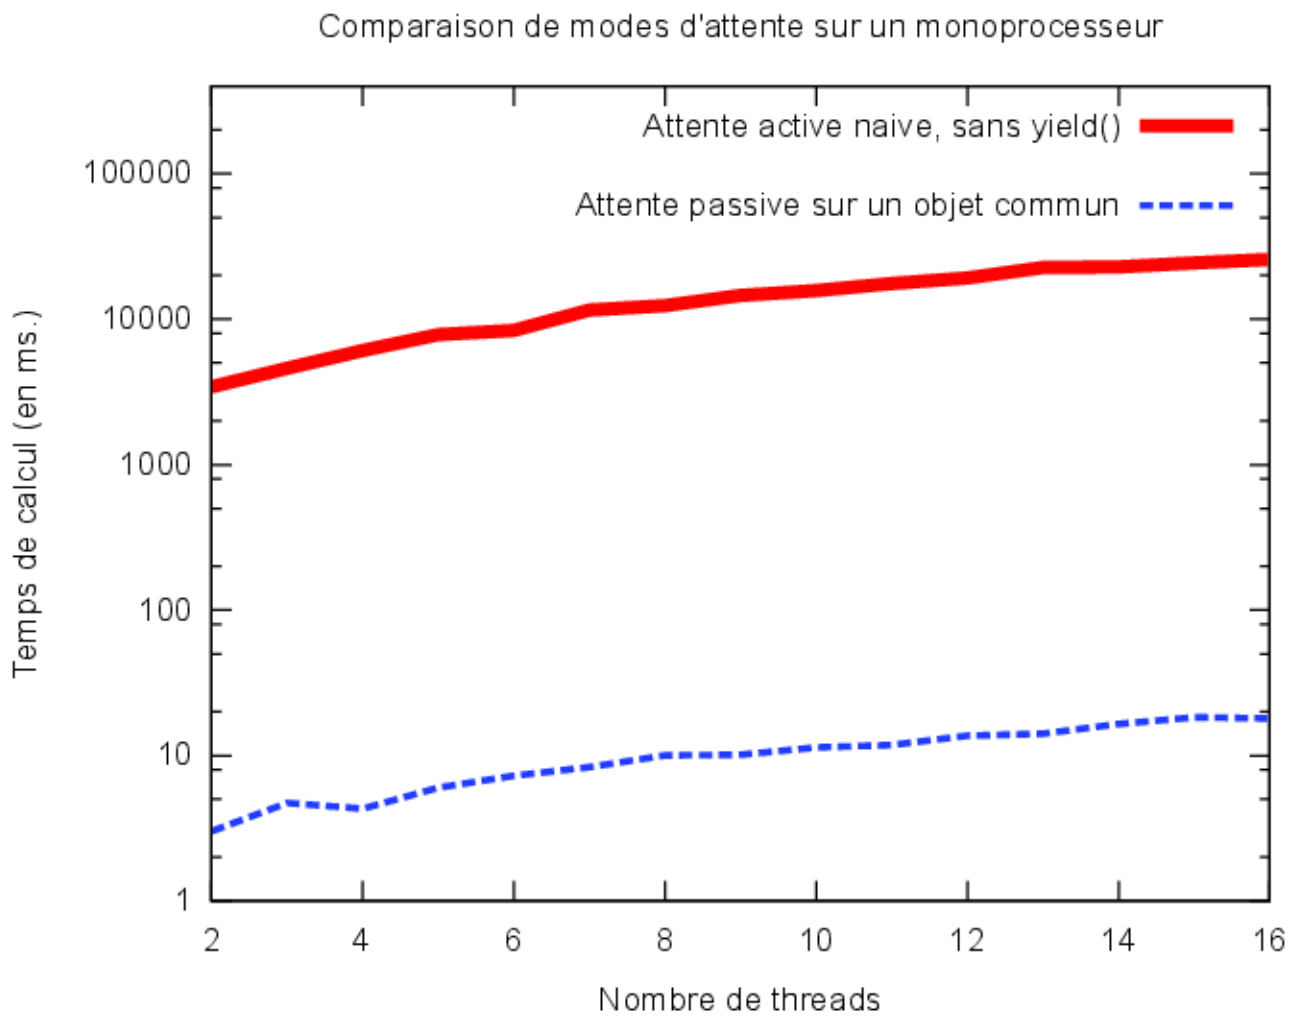

Le temps de calcul est bien moindre avec une attente passive. Il est un millier de fois plus élevé avec une attente active, car chaque thread actif sur le processeur consomme sa tranche de temps en entier (même si ce n'est pas son tour d'incrémenter).

Rôle et apport de l'instruction yield()

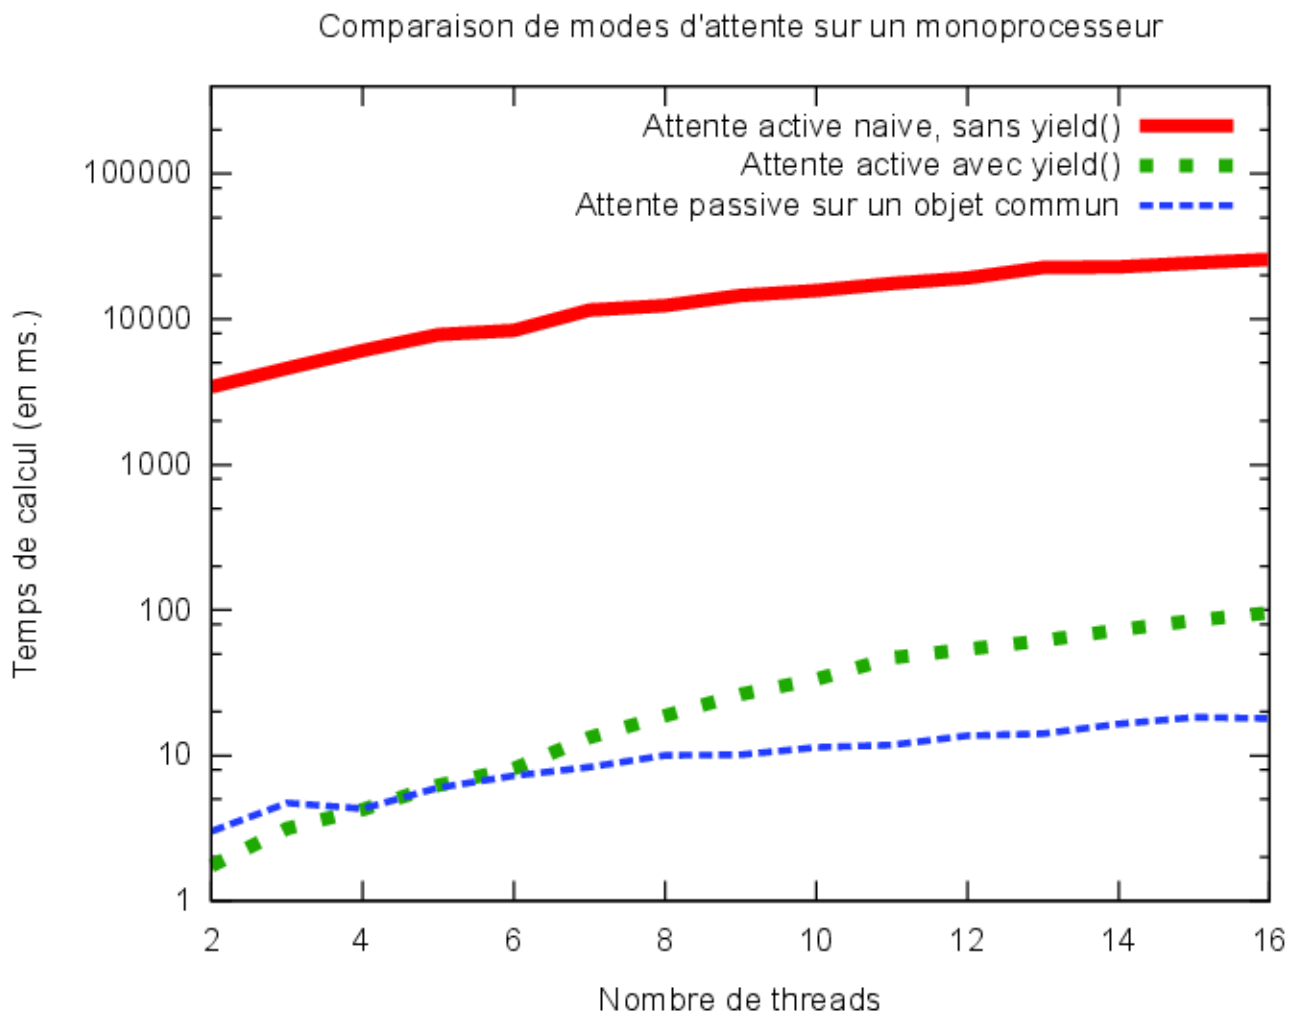

Attendre via **`while(tour!=id) yield();`** permet de relâcher le processeur pour ne pas gâcher la tranche de temps allouée ; néanmoins, sur cette machine le relâchement ne semble pas instantanné puisque l'attente passive reste plus efficace s'il y a plus de 6 threads.

Réduction de nombre de signaux et de réveils

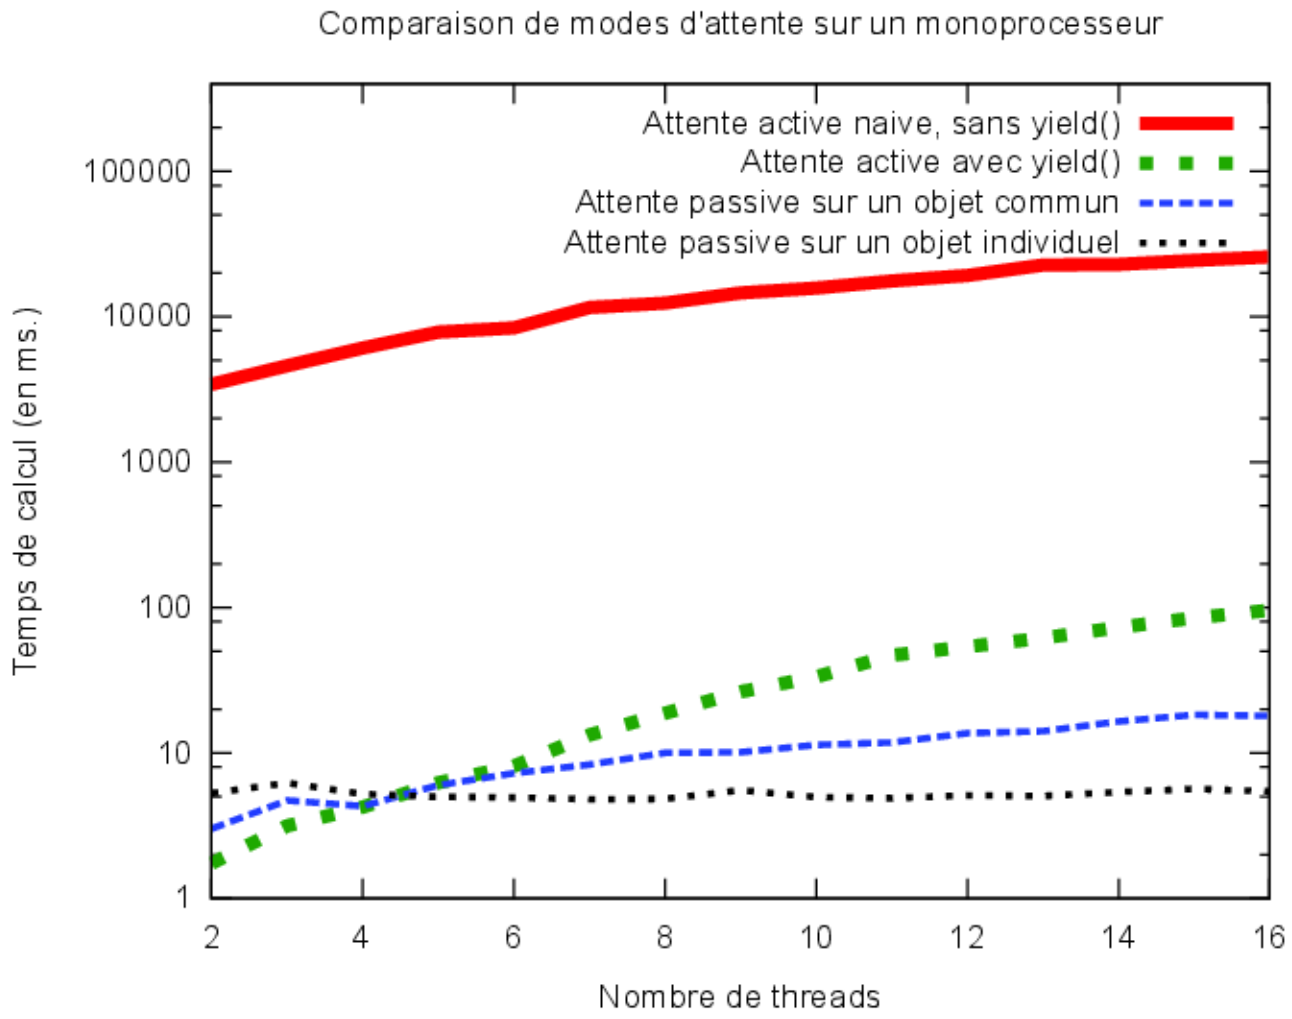

Pour réduire le nombre de signaux envoyés à chaque phase, et ne réveiller que le thread dont c'est le tour d'incrémenter, il faut appliquer **`wait()`** et **`notify()`** sur des objets distincts.

Résultats sur une machine récente, à 8 coeurs (avec plus d'incrémentations)

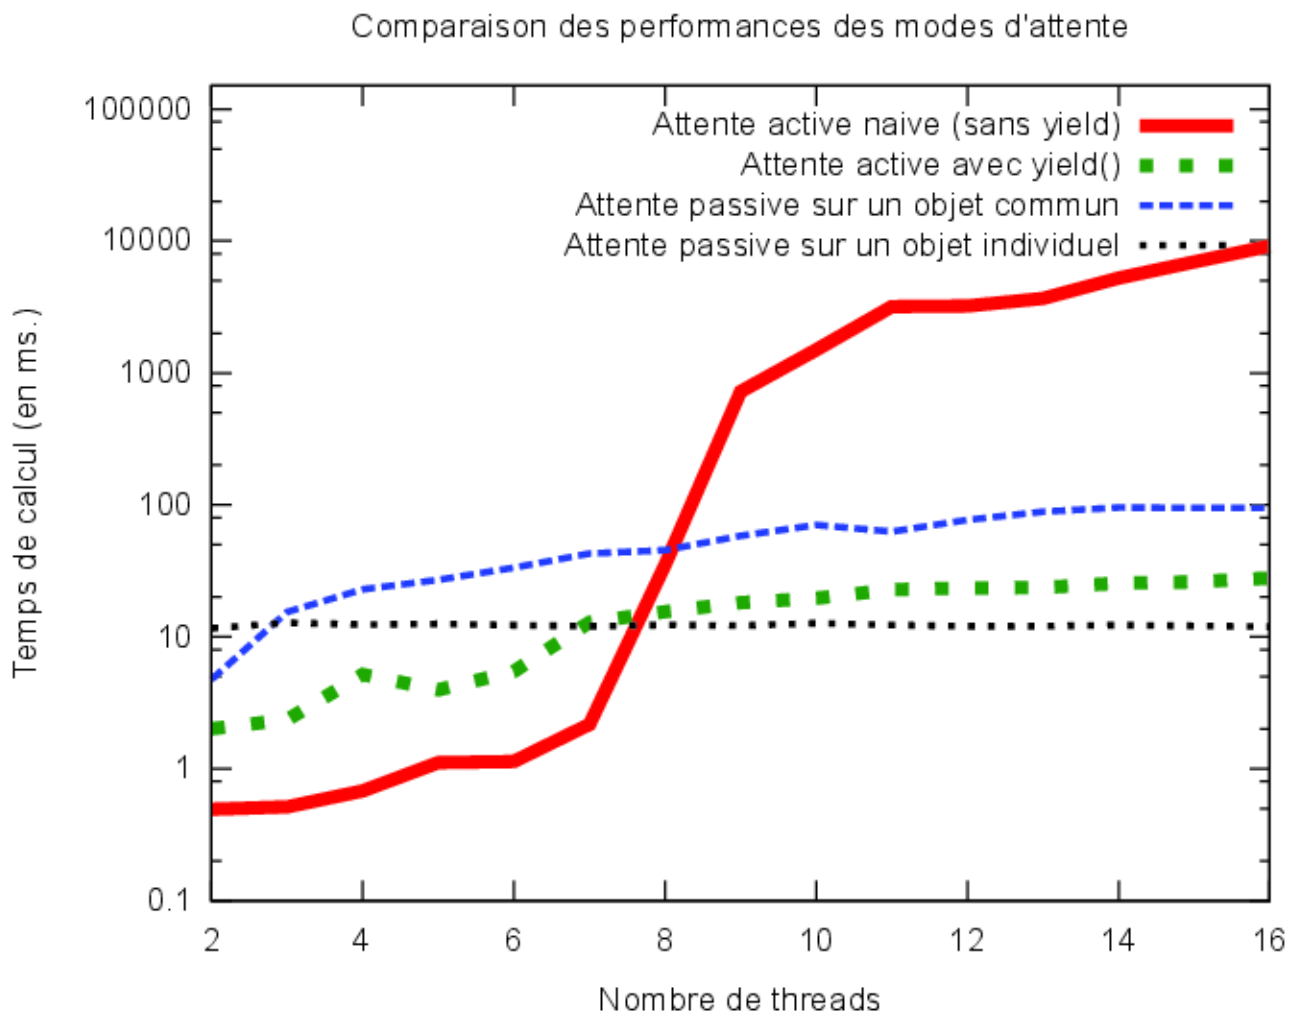

Tant que le nombre de threads est inférieur au nombre de coeurs, l'attente active naïve est la plus efficace. Sur cette machine, **`yield()`** semble plus rapide que le mécanisme des signaux envoyés à tous ; mais l'envoi d'un seul signal demeure l'implémentation la plus efficace.

Conclusions

Dans le cas d'un monoprocesseur, l'attente active est proscrite :

- Le processus attend qu'une condition soit satisfaite ;
- Le seul processus actif ne fait rien : il attend ;
- Aucune modification n'est effectuée sur les données.

⇝ La tranche de temps allouée est donc purement gaspillée !

⇝ Il faut, au minimum, susciter le relâchement par `yield()`.

C'était une règle générale il y a quelques années !

En revanche, dans un environnement multiprocesseur, l'attente active peut être efficace

- si le temps d'attente est moindre qu'un changement de contexte ;
- ou s'il n'y a pas d'autres threads actifs sur le processeur.